

数据分析与实践 实验三 实验报告

PB23151799 时分

实验目的

PISA (Programme for International Student Assessment) 是由经济合作与发展组织发起的一项全球性的教育评估项目，旨在评估15岁学生运用阅读、数学和科学领域的核心素养，并通过大规模的跨国数据收集和分析，为各国教育政策的制定提供参考依据。本实验在Python环境下，通过 `pandas`、`scipy`、`matplotlib` 等库的方法，利用PISA 2018 School Questionnaire的数据集进行探索性分析、可视化分析和特征关系分析。

实验内容

任务1：数据集读取、信息处理和探索性分析

使用 `pandas` 库的相关方法，进行数据集读取、信息处理和探索性分析。

Q1. 读取数据集 `data.csv` (将首列作为索引) 至变量 `df`，展示该数据集的前10行内容，并展示数据集有多少行和多少列。

采用 `pandas` 库中的 `dataframe` 类存储数据。

代码：

```
import pandas as pd

df = pd.read_csv("data.csv")    # 读取csv文件，存储为dataframe类型
print(df.head(10))             # 输出前10行内容
print(f"数据集行数: {df.shape[0]}, 列数: {df.shape[1]}")    # 输出行数与列数
```

结果：

Unnamed: 0	CNTRYID	CNT	CNTSCHID	CYC	NatCen	Region	STRATUM	\
0	1	8	ALB	800002	07MS	800	800	ALB0109
1	2	8	ALB	800003	07MS	800	800	ALB0109
2	3	8	ALB	800004	07MS	800	800	ALB0211
3	4	8	ALB	800005	07MS	800	800	ALB0107
4	5	8	ALB	800006	07MS	800	800	ALB0105
5	6	8	ALB	800007	07MS	800	800	ALB0109
6	7	8	ALB	800008	07MS	800	800	ALB0210
7	8	8	ALB	800009	07MS	800	800	ALB0203
8	9	8	ALB	800010	07MS	800	800	ALB0210
9	10	8	ALB	800011	07MS	800	800	ALB0206

	SUBNATIO	OECD	...	EDUSHORT	STAFFSHORT	STUBEHA	TEACHBEHA	SCMCEG	\
0	80000	0	...	1.2478	-1.4551	-1.1797	-2.0409	-1.0391	
1	80000	0	...	0.6221	-1.4551	2.1196	2.5150	-1.0542	
2	80000	0	...	0.4591	-1.4551	-0.6199	-0.4415	0.9042	
3	80000	0	...	1.3065	1.2432	-0.2682	-0.0452	-1.5648	
4	80000	0	...	-0.2376	-1.4551	-1.3196	-2.0409	0.9042	

5	80000	0	...	0.8339	0.0055	-3.3785	-0.9173	0.1329
6	80000	0	...	-1.4212	-1.4551	-2.0719	-2.0409	0.9042
7	80000	0	...	0.1000	-0.0963	0.6482	1.3992	0.1329
8	80000	0	...	-1.4212	-1.4551	-2.0719	-2.0409	0.9042
9	80000	0	...	-1.4212	-0.5869	-0.9148	-0.6289	-2.5190

	W_SCHGRNRABWT	W_FSTUWT_SCH_SUM	SENWT	VER_DAT	BOOKID
0	7.98891	115.10603	24.81933	09MAY19:11:20:57	NaN
1	6.50492	26.01970	20.20900	09MAY19:11:20:57	NaN
2	6.64198	99.62974	20.63480	09MAY19:11:20:57	NaN
3	5.93762	66.50133	18.44654	09MAY19:11:20:57	NaN
4	14.61508	277.68645	45.40500	09MAY19:11:20:57	NaN
5	6.50492	19.51477	20.20900	09MAY19:11:20:57	NaN
6	1.00000	12.92284	3.10672	09MAY19:11:20:57	NaN
7	1.00000	145.00000	3.10672	09MAY19:11:20:57	NaN
8	1.00000	7.81752	3.10672	09MAY19:11:20:57	NaN
9	6.74868	74.23544	20.96627	09MAY19:11:20:57	NaN

[10 rows x 198 columns]
数据集行数：21903，列数：198

Q2. 数据集存在很多缺失值，输出各列缺失值的个数，并删除数据集的最后一列。基于更新后的数据，展示哪一列的缺失值最多，哪些列没有缺失值。

统计各列缺失值个数时，采用对每列所有值应用 `isna()` 方法再求和的操作。

代码：

```
col_names = df.columns    # 取所有列名，方便展示
for col in col_names:
    num_isnull = df[col].isna().sum()    # 统计缺失值个数
    print(f"列名: {col}, 缺失值数: {num_isnull}")

df.drop(col, axis=1, inplace=True)    # 删除最后一列

col_names = df.columns    # 更新列名
max = 0    # 记录缺失值最大值
col_no_null = []    # 记录无缺失值列名
col_max_null = []    # 记录缺失值最多的列名（可能存在多个）

for col in col_names:
    num_isnull = df[col].isna().sum()
    if num_isnull == 0:
        col_no_null.append(col)    # 无缺失值
    if num_isnull > max:
        max = num_isnull    # 更新最多缺失值

for col in col_names:
    num_isnull = df[col].isna().sum()
    if max == num_isnull:
        col_max_null.append(col)    # 缺失值最多的列

print(f"缺失值最多的列为: ")
for col in col_max_null:
    print(f"\t{col}")
print(f"无缺失值的列为: ")
for col in col_no_null:
```

```
print(f"\t{col}")
```

结果:

```
列名: Unnamed: 0, 缺失值数: 0
列名: CNTRYID, 缺失值数: 0
列名: CNT, 缺失值数: 0
列名: CNTSCHID, 缺失值数: 0
列名: CYC, 缺失值数: 0
列名: NatCen, 缺失值数: 0
列名: Region, 缺失值数: 0
列名: STRATUM, 缺失值数: 0
列名: SUBNATIO, 缺失值数: 0
列名: OECD, 缺失值数: 0
列名: ADMINMODE, 缺失值数: 0
列名: LANGTEST, 缺失值数: 786
列名: SC001Q01TA, 缺失值数: 1363
列名: SC013Q01TA, 缺失值数: 2092
列名: SC016Q01TA, 缺失值数: 3050
列名: SC016Q02TA, 缺失值数: 5603
列名: SC016Q03TA, 缺失值数: 6162
列名: SC016Q04TA, 缺失值数: 6793
列名: SC017Q01NA, 缺失值数: 1093
列名: SC017Q02NA, 缺失值数: 1149
列名: SC017Q03NA, 缺失值数: 1155
列名: SC017Q04NA, 缺失值数: 1244
列名: SC017Q05NA, 缺失值数: 1074
列名: SC017Q06NA, 缺失值数: 1111
列名: SC017Q07NA, 缺失值数: 1059
列名: SC017Q08NA, 缺失值数: 1072
列名: SC161Q01SA, 缺失值数: 1499
列名: SC161Q02SA, 缺失值数: 1499
列名: SC161Q03SA, 缺失值数: 1499
列名: SC161Q04SA, 缺失值数: 1499
列名: SC161Q05SA, 缺失值数: 1499
列名: SC162Q01SA, 缺失值数: 3657
列名: SC155Q01HA, 缺失值数: 1030
列名: SC155Q02HA, 缺失值数: 1041
列名: SC155Q03HA, 缺失值数: 1074
列名: SC155Q04HA, 缺失值数: 1041
列名: SC155Q05HA, 缺失值数: 1042
列名: SC155Q06HA, 缺失值数: 1027
列名: SC155Q07HA, 缺失值数: 1029
列名: SC155Q08HA, 缺失值数: 1035
列名: SC155Q09HA, 缺失值数: 1065
列名: SC155Q10HA, 缺失值数: 1054
列名: SC155Q11HA, 缺失值数: 1026
列名: SC156Q01HA, 缺失值数: 1034
列名: SC156Q02HA, 缺失值数: 1073
列名: SC156Q03HA, 缺失值数: 1093
列名: SC156Q04HA, 缺失值数: 1052
列名: SC156Q05HA, 缺失值数: 1062
列名: SC156Q06HA, 缺失值数: 1066
列名: SC156Q07HA, 缺失值数: 1076
列名: SC156Q08HA, 缺失值数: 1050
列名: SC011Q01TA, 缺失值数: 1015
列名: SC012Q01TA, 缺失值数: 1155
```

列名: SC012Q02TA, 缺失值数: 1243
列名: SC012Q03TA, 缺失值数: 1244
列名: SC012Q04TA, 缺失值数: 1248
列名: SC012Q05TA, 缺失值数: 1223
列名: SC012Q06TA, 缺失值数: 1169
列名: SC012Q07TA, 缺失值数: 4812
列名: SC042Q01TA, 缺失值数: 2025
列名: SC042Q02TA, 缺失值数: 1651
列名: SC154Q01HA, 缺失值数: 1315
列名: SC154Q02WA, 缺失值数: 1287
列名: SC154Q03WA, 缺失值数: 1327
列名: SC154Q04WA, 缺失值数: 1347
列名: SC154Q05WA, 缺失值数: 1331
列名: SC154Q06WA, 缺失值数: 1314
列名: SC154Q07WA, 缺失值数: 1338
列名: SC154Q08WA, 缺失值数: 1319
列名: SC154Q09HA, 缺失值数: 1334
列名: SC154Q10WA, 缺失值数: 1350
列名: SC154Q11HA, 缺失值数: 1346
列名: SC036Q01TA, 缺失值数: 1133
列名: SC036Q02TA, 缺失值数: 1128
列名: SC036Q03NA, 缺失值数: 1051
列名: SC037Q01TA, 缺失值数: 1110
列名: SC037Q02TA, 缺失值数: 1202
列名: SC037Q03TA, 缺失值数: 1284
列名: SC037Q04TA, 缺失值数: 1212
列名: SC037Q05NA, 缺失值数: 1130
列名: SC037Q06NA, 缺失值数: 1132
列名: SC037Q07TA, 缺失值数: 1146
列名: SC037Q08TA, 缺失值数: 1183
列名: SC037Q09TA, 缺失值数: 1149
列名: SC037Q10NA, 缺失值数: 1178
列名: SC165Q01HA, 缺失值数: 4349
列名: SC165Q02HA, 缺失值数: 4372
列名: SC165Q03HA, 缺失值数: 4366
列名: SC165Q04HA, 缺失值数: 4385
列名: SC165Q05HA, 缺失值数: 4392
列名: SC165Q06HA, 缺失值数: 4364
列名: SC165Q07HA, 缺失值数: 4380
列名: SC165Q08HA, 缺失值数: 4393
列名: SC165Q09HA, 缺失值数: 4386
列名: SC165Q10HA, 缺失值数: 4379
列名: SC166Q02HA, 缺失值数: 4525
列名: SC166Q03HA, 缺失值数: 4537
列名: SC166Q05HA, 缺失值数: 4542
列名: SC166Q06HA, 缺失值数: 5238
列名: SC167Q01HA, 缺失值数: 3270
列名: SC167Q02HA, 缺失值数: 3254
列名: SC167Q03HA, 缺失值数: 3283
列名: SC167Q04HA, 缺失值数: 3267
列名: SC167Q05HA, 缺失值数: 3241
列名: SC167Q06HA, 缺失值数: 3269
列名: SC158Q01HA, 缺失值数: 4006
列名: SC158Q02HA, 缺失值数: 4024
列名: SC158Q04HA, 缺失值数: 4036
列名: SC158Q07HA, 缺失值数: 4051
列名: SC158Q08HA, 缺失值数: 4056
列名: SC158Q09HA, 缺失值数: 4049

列名: SC158Q12HA, 缺失值数: 4051
列名: SC061Q01TA, 缺失值数: 1080
列名: SC061Q02TA, 缺失值数: 1081
列名: SC061Q03TA, 缺失值数: 1103
列名: SC061Q04TA, 缺失值数: 1092
列名: SC061Q05TA, 缺失值数: 1080
列名: SC061Q11HA, 缺失值数: 1070
列名: SC061Q06TA, 缺失值数: 1083
列名: SC061Q07TA, 缺失值数: 1085
列名: SC061Q08TA, 缺失值数: 1086
列名: SC061Q09TA, 缺失值数: 1071
列名: SC061Q10TA, 缺失值数: 1078
列名: SC002Q01TA, 缺失值数: 3928
列名: SC002Q02TA, 缺失值数: 3918
列名: SC048Q01NA, 缺失值数: 4524
列名: SC048Q02NA, 缺失值数: 3854
列名: SC048Q03NA, 缺失值数: 2982
列名: SC004Q01TA, 缺失值数: 3281
列名: SC004Q02TA, 缺失值数: 1979
列名: SC004Q03TA, 缺失值数: 2432
列名: SC004Q04NA, 缺失值数: 2617
列名: SC004Q05NA, 缺失值数: 1583
列名: SC004Q06NA, 缺失值数: 1572
列名: SC004Q07NA, 缺失值数: 1802
列名: SC018Q01TA01, 缺失值数: 3314
列名: SC018Q01TA02, 缺失值数: 5169
列名: SC018Q02TA01, 缺失值数: 5872
列名: SC018Q02TA02, 缺失值数: 7334
列名: SC018Q05NA01, 缺失值数: 4920
列名: SC018Q05NA02, 缺失值数: 7118
列名: SC018Q06NA01, 缺失值数: 4448
列名: SC018Q06NA02, 缺失值数: 7395
列名: SC018Q07NA01, 缺失值数: 4413
列名: SC018Q07NA02, 缺失值数: 7519
列名: SC025Q01NA, 缺失值数: 1752
列名: SC159Q01HA, 缺失值数: 1346
列名: SC003Q01TA, 缺失值数: 2663
列名: SC053Q01TA, 缺失值数: 1685
列名: SC053Q02TA, 缺失值数: 1640
列名: SC053Q03TA, 缺失值数: 1723
列名: SC053Q04TA, 缺失值数: 1521
列名: SC053Q12IA, 缺失值数: 1745
列名: SC053Q13IA, 缺失值数: 1738
列名: SC053Q09TA, 缺失值数: 1663
列名: SC053Q10TA, 缺失值数: 1465
列名: SC053Q14IA, 缺失值数: 1584
列名: SC053Q15IA, 缺失值数: 1685
列名: SC053Q16IA, 缺失值数: 1781
列名: SC053D11TA, 缺失值数: 0
列名: SC150Q01IA, 缺失值数: 2579
列名: SC150Q02IA, 缺失值数: 2704
列名: SC150Q03IA, 缺失值数: 2757
列名: SC150Q04IA, 缺失值数: 2759
列名: SC150Q05IA, 缺失值数: 2732
列名: SC164Q01HA, 缺失值数: 5405
列名: SC064Q01TA, 缺失值数: 1837
列名: SC064Q02TA, 缺失值数: 1798
列名: SC064Q03TA, 缺失值数: 2331

列名: SC064Q04NA, 缺失值数: 4667
列名: SC152Q01HA, 缺失值数: 1138
列名: SC160Q01WA, 缺失值数: 11450
列名: SC052Q01NA, 缺失值数: 1413
列名: SC052Q02NA, 缺失值数: 1567
列名: SC052Q03HA, 缺失值数: 1465
列名: PRIVATESCH, 缺失值数: 596
列名: SCHLTYPE, 缺失值数: 1571
列名: STRATIO, 缺失值数: 3861
列名: SCHSIZE, 缺失值数: 3582
列名: RATCMP1, 缺失值数: 4001
列名: RATCMP2, 缺失值数: 3779
列名: TOTAT, 缺失值数: 3052
列名: PROATCE, 缺失值数: 3726
列名: PROAT5AB, 缺失值数: 3224
列名: PROAT5AM, 缺失值数: 2879
列名: PROAT6, 缺失值数: 3016
列名: CLSIZE, 缺失值数: 2663
列名: CREATIV, 缺失值数: 1465
列名: EDUSHORT, 缺失值数: 1151
列名: STAFFSHORT, 缺失值数: 1138
列名: STUBEHA, 缺失值数: 1040
列名: TEACHBEHA, 缺失值数: 1057
列名: SCMCEG, 缺失值数: 4534
列名: W_SCHGRNRABWT, 缺失值数: 0
列名: W_FSTUWT_SCH_SUM, 缺失值数: 0
列名: SENWT, 缺失值数: 0
列名: VER_DAT, 缺失值数: 0
列名: BOOKID, 缺失值数: 21903

缺失值最多的列为:

SC160Q01WA

无缺失值的列为:

Unnamed: 0

CNTRYID

CNT

CNTSCHID

CYC

NatCen

Region

STRATUM

SUBNATIO

OECD

ADMINMODE

SC053D11TA

W_SCHGRNRABWT

W_FSTUWT_SCH_SUM

SENWT

VER_DAT

Q3. 数据集的有些列在所有记录上均有相同取值，作为独立的一列是相对冗余的。请查找并输出这些列的名称和取值，并阐述这些列代表的含义，最后删除这些列。

`nunique()` 方法可以输出 `dataframe` 一列中的取值种类数，若 `nunique()` 返回值为1，则说明该列在所有记录上均有相同取值。采用字典 `col_dup` 存储列名和取值。

代码:

```
col_dup = {} # 记录冗余列名和取值
for col in col_names:
    if df[col].nunique() == 1:
        col_dup[col] = df[col].iloc[0] # 列中只有一种数值

print("冗余列: ")
for col, value in col_dup.items():
    print(f"\t列名: {col}, 取值: {value}")

df.drop(columns=list(col_dup.keys()), inplace=True) # 删除冗余列
```

结果:

```
冗余列:
列名: CYC, 取值: 07MS
列名: ADMINMODE, 取值: 2
```

查找 `codebook.xlsx` 文件, 得到两列的含义分别为:

CYC: PISA Assessment Cycle (2 digits + 2 character Assessment type - MS/FT). 即记录评估类型与周期, 取值均为07MS。

ADMINMODE: Mode of Respondent (1 Paper, 2 Computer, SYSTEM MISSING Missing). 即调查模式, 均使用计算机调查。

Q4. 观察 `PRIVATESCH` 特征列, 统计所有取值及其出现的次数。其中有一部分取值含义一致但形式不同 (如 `private` 和 `PRIVATE`) , 试对它们进行归并, 随后展示所有取值及其出现的次数。

`value_counts` 方法可以返回一个 `Series`, 包括某列每种取值和出现的次数 (不包括空值) 。

代码:

```
value_count = df["PRIVATESCH"].value_counts() # 统计所有取值及其出现的次数
print("取值及出现次数: ")
for value, count in value_count.items():
    print(f"\t取值: {value}, 次数: {count}")
```

结果:

```
取值及出现次数:
取值: public, 次数: 12161
取值: missing, 次数: 5295
取值: private, 次数: 3443
取值: invalid, 次数: 251
取值: PRIVATE, 次数: 84
取值: PUBLIC, 次数: 73
```

发现 `PRIVATE`、`PUBLIC` 与其它值形式不同, 采用 `replace()` 方法统一进行重新赋值, 并再次展示。

代码:

```
df["PRIVATESCH"] = df["PRIVATESCH"].replace(to_replace="PUBLIC", value="public")
df["PRIVATESCH"] = df["PRIVATESCH"].replace(to_replace="PRIVATE",
value="private") # 归并

value_count = df["PRIVATESCH"].value_counts() # 统计所有取值及其出现的次数
print("取值及出现次数: ")
for value, count in value_count.items():
    print(f"\t取值: {value}, 次数: {count}")
```

结果:

```
取值及出现次数:
取值: public, 次数: 12234
取值: missing, 次数: 5295
取值: private, 次数: 3527
取值: invalid, 次数: 251
```

Q5. 选取特征 STUBEHA, TEACHBEHA, EDUSHORT, STAFFSHORT, 展示它们的基本统计特征信息（平均值、标准差、四分位点、最小值、最大值、Pearson相关系数矩阵）。

这些基本统计特征信息都可以使用 `Dataframe` 类的相关方法实现，包括：

- 均值: `mean()`
- 标准差: `std()`
- p分位数: `quantile(p)` ($p \in [0, 1]$)
- 最大值: `max()`
- 最小值: `min()`
- Pearson相关系数矩阵: `corr(method='pearson')`

代码:

```
features = ["STUBEHA", "TEACHBEHA", "EDUSHORT", "STAFFSHORT"] # 需统计的特征

for col in features:
    print(f"列{col}的基本统计特征信息:")
    print(f"\t平均值: {df[col].mean()}")
    print(f"\t标准差: {df[col].std()}")
    print(f"\t25%分位数: {df[col].quantile(0.25)}")
    print(f"\t50%分位数: {df[col].quantile(0.5)}")
    print(f"\t75%分位数: {df[col].quantile(0.75)}")
    print(f"\t最大值: {df[col].max()}")
    print(f"\t最小值: {df[col].min()}")

pearson_matrix = df[features].corr(method="pearson")
print("Pearson相关系数矩阵: ")
print(pearson_matrix)
```

结果:

```
列STUBEHA的基本统计特征信息:
平均值: 0.041613881033408434
标准差: 1.2365311162988104
25%分位数: -0.6823
```

50%分位数: 0.0417
75%分位数: 0.8153
最大值: 3.6274
最小值: -4.3542

列TEACHBEHA的基本统计特征信息:

平均值: 0.10823287441235728
标准差: 1.1581542742625597
25%分位数: -0.6218
50%分位数: 0.2266
75%分位数: 0.852425
最大值: 3.8338
最小值: -3.2392

列EDUSHORT的基本统计特征信息:

平均值: 0.1207159936391673
标准差: 1.091434381478892
25%分位数: -0.6884
50%分位数: 0.1
75%分位数: 0.8339
最大值: 3.5229
最小值: -1.9319

列STAFFSHORT的基本统计特征信息:

平均值: -0.013901473633517942
标准差: 1.059586752743767
25%分位数: -0.7828
50%分位数: 0.0131
75%分位数: 0.6736
最大值: 4.1125
最小值: -2.5891

Pearson相关系数矩阵:

	STUBEHA	TEACHBEHA	EDUSHORT	STAFFSHORT
STUBEHA	1.000000	0.633862	0.239674	0.257259
TEACHBEHA	0.633862	1.000000	0.215399	0.331982
EDUSHORT	0.239674	0.215399	1.000000	0.483617
STAFFSHORT	0.257259	0.331982	0.483617	1.000000

Q6. Q5中所得Pearson相关系数矩阵显示, 特征 STUBEHA 与 TEACHBEHA 之间、EDUSHORT 与 STAFFSHORT 的相关系数较高, 请通过特征定义推测可能导致相关性的原因。

根据codebook中的特征定义:

STUBEHA: Student behaviour hindering learning (WLE)

TEACHBEHA: Teacher behaviour hindering learning (WLE)

EDUSHORT: Shortage of educational material (WLE)

STAFFSHORT: Shortage of educational staff (WLE)

原因推测: 在相同地区/学校, 学生和教师可能会具有类似的阻碍学习的行为 (如受到当地民俗、文化等影响, 或是当地经济落后让学生和教师均需要放弃一部分学习时间参与劳动等); 在落后地区, 往往同时出现教育资源缺乏和教育人员缺乏的情况。

Q7. 执行子表提取操作, 并基于子表 df1, 以特征 PRIVATESCH 为先验条件, 对其余各特征中可能存在的缺失值进行均值填补。

子表提取: `df1 = df[['PRIVATESCH', 'EDUSHORT', 'STAFFSHORT']]`

根据特征 `PRIVATESCH` 的取值类型（包括空值）分组，分别计算每组的 `EDUSHORT`、`STAFFSHORT` 非空取值的均值，并遍历每个记录填补缺失处，输出填补前后的缺失值个数。

代码：

```
df1 = df[['PRIVATESCH', 'EDUSHORT', 'STAFFSHORT']] # 子表提取

# 展示填补前缺失值个数
print("填补前：")
for col in df1.columns:
    num_isnull = df1[col].isna().sum() # 统计缺失值个数
    print(f"列名：{col}，缺失值数：{num_isnull}")

# 按PRIVATESCH分组（包括空值），计算均值，得到两个记录了均值的Series
edu_mean = df1.groupby("PRIVATESCH", dropna=False)['EDUSHORT'].mean()
staff_mean = df1.groupby("PRIVATESCH", dropna=False)['STAFFSHORT'].mean()

# 将均值填补至缺失处
for i in range(df1.shape[0]):
    privatesch = df1.loc[i, "PRIVATESCH"]
    if pd.isna(df1.loc[i, "EDUSHORT"]):
        df1.loc[i, "EDUSHORT"] = edu_mean[privatesch]
    if pd.isna(df1.loc[i, "STAFFSHORT"]):
        df1.loc[i, "STAFFSHORT"] = staff_mean[privatesch]

# 展示填补后缺失值个数
print("填补后：")
for col in df1.columns:
    num_isnull = df1[col].isna().sum() # 统计缺失值个数
    print(f"列名：{col}，缺失值数：{num_isnull}")
```

结果：

```
填补前：
列名：PRIVATESCH，缺失值数：596
列名：EDUSHORT，缺失值数：1151
列名：STAFFSHORT，缺失值数：1138
填补后：
列名：PRIVATESCH，缺失值数：596
列名：EDUSHORT，缺失值数：0
列名：STAFFSHORT，缺失值数：0
```

任务2：数据集可视化分析

导入 `numpy` 和 `matplotlib` 库，对数据集 `df` 进行一定数据可视化分析。

Q1. 选择两个连续数值型特征，绘制其分布散点图，要求合理设置散点颜色 and 大小，并配上合适的标题和图例注记。


选择 `EDUSHORT` 和 `STAFFSHORT` 特征，利用 `matplotlib.pyplot` 中的 `scatter()` 函数绘制分布散点图。

代码：

```
import numpy as np
import matplotlib.pyplot as plt

# 展示EDUSHORT和STAFFSHORT的分布散点图
plt.figure(figsize=(16, 10))
plt.scatter(df["EDUSHORT"], df["STAFFSHORT"], color="navy", label="data", s=5,
            alpha=0.4)
plt.xlabel("EDUSHORT")
plt.ylabel("STAFFSHORT")
plt.title("EDUSHORT-STAFFSHORT Data Points")
plt.legend()
plt.grid(True)
plt.show()
```

结果：




Q2. 选择一个离散数值型特征（建议所有取值数量不超过10），绘制饼图，要求设置合理配色和比例，并配上合适的标题和图例注记。

选择 PRIVATESCH 特征，在用 value_count 方法统计取值（包括空值）个数后，利用 matplotlib.pyplot 中的 pie() 函数绘制饼图。

代码：

```
# 展示PRIVATESCH的分布饼图
value_count = df["PRIVATESCH"].value_counts(dropna=False)
plt.figure(figsize=(8,5))
plt.pie(value_count.values, labels=value_count.keys(), autopct='%1.1f%%',
        startangle=140)
plt.title("PRIVATESCH Distribution")
plt.axis("equal")
plt.show()
```

结果：



Q3. 对T1-Q5中的Pearson相关系数矩阵，绘制热力矩阵图，要求为每个位置增添对应数值表示（保留三位小数），设置数值与颜色的对应关系条，并配上合适的标题和坐标表示。

绘制热力矩阵图可以直接利用 `matplotlib.pyplot` 中的 `imshow()` 函数完成。增添数值表示需要利用 `text()` 函数，为标识清晰，按热力图颜色深浅更改文本颜色（阈值为0.7），并使用 `xticks()`、`yticks()` 函数绘制标签。颜色对照条则使用 `colorbar()` 函数生成。


代码：

```
plt.figure(figsize=(8,6))
plt.imshow(pearson_matrix, cmap="gray", interpolation="nearest")    # 绘制热力图

# 标记数值
for i in range(pearson_matrix.shape[0]):
    for j in range(pearson_matrix.shape[1]):
        if pearson_matrix.iloc[i,j] > 0.7:
            plt.text(j, i, f'{pearson_matrix.iloc[i,j]:.3f}', ha='center',
va='center', color='black')
        else:
            plt.text(j, i, f'{pearson_matrix.iloc[i,j]:.3f}', ha='center',
va='center', color='white')

plt.title("Pearson Matrix")
# 标记坐标标签
plt.xticks([0, 1, 2, 3],pearson_matrix.keys())
plt.yticks([0, 1, 2, 3],pearson_matrix.keys())
# 绘制数值与颜色的对应关系条
plt.colorbar()
plt.show()
```

结果：



任务3：特征分布校验

现欲对数据集特征 STUBEHA, TEACHBEHA 进行分布校验。执行以下子表提取和缺失记录删除操作：`df2 = df[['STUBEHA', 'TEACHBEHA']].dropna()`

Q1. 以区间数为10，分别绘制两个特征的频数直方图，基于频数直方图的结果，是否可以认为两特征近似服从正态分布？

利用 `matplotlib.pyplot` 中的 `hist()` 函数绘制频数直方图，参数 `bins=10` 表示区间数为10。

代码：



```
df2 = df[['STUBEHA', 'TEACHBEHA']].dropna()

# 绘制STUBEHA的直方图
plt.figure(figsize=(8,6))
plt.hist(df2["STUBEHA"], bins=10, color="skyblue", edgecolor="black",
linewidth=2)
plt.xlabel("STUBEHA")
plt.ylabel("frequency")
plt.title("Histogram of STUBEHA")
plt.show()

# 绘制TEACHBEHA的直方图
plt.figure(figsize=(8,6))
plt.hist(df2["TEACHBEHA"], bins=10, color="skyblue", edgecolor="black",
linewidth=2)
plt.xlabel("TEACHBEHA")
plt.ylabel("frequency")
plt.title("Histogram of TEACHBEHA")
```

```
plt.show()
```

结果:



两个频数直方图均呈现中间高、两边低的趋势，可认为均近似服从正态分布。

Q2. 分别绘制这两个特征样本的Q-Q图，基于Q-Q图的结果，是否可以认为两特征近似服从正态分布？将该结论与Q1所得结论进行对比，你有什么感想？

Q-Q图 (Quantile-Quantial Plot) 又称为分位图，可简单直观地判断一组数据是否服从某种理论分布。例如，若一容量为 n 的样本 X 服从标准正态分布，则其各分位点应与标准正态分布对应分位点完全一致。若从标准正态分布抽样得到容量为 n 的样本 Y ，则散点 (x_i, y_i) 将近似分布于直线 $y=x$ 上。

利用 `statsmodels.api` 库中 `sm` 类的 `qqplot()` 方法绘制Q-Q图。


代码：


```
import statsmodels.api as sm

plt.figure(figsize=(8,6))
sm.qqplot(df2["STUBEHA"], line="45")
plt.title("Q-Q Plot of STUBEHA")
plt.show()

plt.figure(figsize=(8,6))
sm.qqplot(df2["TEACHBEHA"], line="45")
plt.title("Q-Q Plot of TEACHBEHA")
plt.show()
```

结果：





Q-Q图中两图像最大、最小值侧偏离较明显，中间部分大体位于 $y=x$ 上，可以认为两特征近似服从正态分布，但的确存在一定偏离。

Q1中基于频数直方图的趋势猜测数据服从正态分布，结论不一定准确，并且当分组步长不够短时常常观察不到正态分布的特征；在Q-Q图中则可以较明显地表现出分布与正态分布的相似度，相对频数直方图较为准确。

Q3. 特征STUBEHA与TEACHBEHA的理论分布是否具有一致性？请自行编写代码绘制两特征样本的Q-Q图和直线，并基于可视化结果简述你的发现。


先用 `quantile()` 方法求出两个特征的分位数（步长设为0.001），利用 `plt.scatter()` 方法绘制分位数散点，再利用 `plt.plot` 函数绘制 $y=x$ 直线。

代码：

```
# 取分位数，步长为0.1%
quan_stu = [df2["STUBEHA"].quantile(i) for i in np.arange(0, 1, 0.001)]
quan_tea = [df2["TEACHBEHA"].quantile(i) for i in np.arange(0, 1, 0.001)]

# 可视化
plt.figure(figsize=(8,6))
plt.scatter(quan_stu, quan_tea, color="steelblue", s=30) # 散点
plt.plot([-3.5,4.5], [-3.5,4.5], color="red") # 直线
plt.xlabel("Quantiles of STUBEHA")
plt.ylabel("Quantiles of TEACHBEHA")
plt.title("Histogram of STUBEHA")
plt.show()
```

结果：



Q-Q图上的点大于-2的部分基本位于 $y=x$ 上，在小于-2部分有所偏移，大致与 $y=x$ 曲线相符合，即可以认为STUBEHA与TEACHBEHA的理论分布具有一致性。

任务4：特征 STUBEHA, TEACHBEHA 的总体分布参数估计

基于正态分布假设，对特征 STUBEHA, TEACHBEHA 的总体分布进行参数估计。

Q1. 假设特征 STUBEHA 和 TEACHBEHA 样本分别独立同分布于正态分布

$N(\mu_1, \sigma_1^2), N(\mu_2, \sigma_2^2)$ ，请分别求均值参数 μ_1, μ_2 和方差参数 σ_1, σ_2 的极大似然估计。作为总体均值和总体方差的估计，样本均值和样本方差均具有无偏性，请问上述极大似然估计是否也同样具有无偏性？

求最大似然估计：

样本独立同分布于正态分布 $N(\mu, \sigma^2)$ ，密度函数为 $f(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$

似然函数 $L(\mu, \sigma^2; X) = \prod_{k=1}^n f(x_k)$

取对数得到

$$\begin{aligned} l(\mu, \sigma^2) &= \sum_{k=1}^n \ln f(x_k) \\ &= \sum_{k=1}^n \left(-\frac{\ln 2\pi}{2} - \ln \sigma - \frac{(x_k - \mu)^2}{2\sigma^2} \right) \\ &= -\frac{n \ln 2\pi}{2} - n \ln \sigma - \frac{1}{2\sigma^2} \sum_{k=1}^n (x_k - \mu)^2 \end{aligned}$$

求驻点，即

$$\frac{\partial l}{\partial \mu} = \frac{1}{2\sigma^2} \sum_{k=1}^n 2(x_k - \mu) = 0$$

$$\frac{\partial l}{\partial (\sigma^2)} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{k=1}^n (x_k - \mu)^2 = 0$$

解得

$$\hat{\mu} = \frac{1}{n} \sum_{k=1}^n x_k = \bar{x}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2 = m_2$$

计算最大似然估计的代码：

```
stu_mu = df2["STUBEHA"].mean()
squared_diffs = (df2["STUBEHA"] - stu_mu) ** 2
stu_sigma2 = squared_diffs.mean()
print(f"STUBEHA的最大似然估计: mu = {stu_mu:.4f}, sigma^2 = {stu_sigma2:.4f}")

teach_mu = df2["TEACHBEHA"].mean()
squared_diffs = (df2["TEACHBEHA"] - stu_mu) ** 2
teach_sigma2 = squared_diffs.mean()
print(f"TEACHBEHA的最大似然估计: mu = {teach_mu:.4f}, sigma^2 = {teach_sigma2:.4f}")
```

结果：

```
STUBEHA的最大似然估计: mu = 0.0411, sigma^2 = 1.5289
TEACHBEHA的最大似然估计: mu = 0.1082, sigma^2 = 1.3458
```

验证无偏性：

$$E\hat{\mu} = E\left(\frac{1}{n} \sum_{k=1}^n x_k\right)$$

$$= \frac{1}{n} \sum_{k=1}^n \mu$$

$$= \mu$$

即 μ 是无偏的。

$$E\hat{\sigma}^2 = E\left(\frac{1}{n} \sum_{k=1}^n (x_k - \bar{x})^2\right)$$

$$= \frac{1}{n} E\left(\sum_{k=1}^n x_k^2 + n\bar{x}^2 - 2\bar{x} \sum_{k=1}^n x_k\right)$$

$$= \frac{1}{n} E\left(\sum_{k=1}^n x_k^2 + n\bar{x}^2 - 2n\bar{x}^2\right)$$

$$= \frac{1}{n} E\left(\sum_{k=1}^n x_k^2 - n\bar{x}^2\right)$$

又

$$\begin{aligned}
E\left(\sum_{k=1}^n x_k^2\right) &= \sum_{k=1}^n E(x_k^2) \\
&= n(\mu^2 + \sigma^2) \\
E(\bar{x}^2) &= \frac{1}{n^2} E\left(\sum_{k=1}^n x_k\right)^2 \\
&= \frac{1}{n^2} E\left(\sum_{k=1}^n x_k^2 + \sum_{i \neq j} x_i x_j\right) \\
&= \frac{1}{n^2} (n(\mu^2 + \sigma^2) + n(n-1)\mu^2) \\
&= \frac{1}{n^2} (n^2\mu^2 + n\sigma^2)
\end{aligned}$$

故

$$E\hat{\sigma}^2 = \frac{n-1}{n}\sigma^2 \neq \sigma^2$$

即 σ^2 是有偏的.

Q2. 设特征 STUBEHA 的样本为 $Y = (y_1, y_2, \dots, y_n)$ ，对该特征进行常数估计 $y = a$ ，求参数 a 的最小二乘解，并比较其与 Q1 中所得总体均值极大似然估计的结果。

即求

$$\operatorname{argmin}_a L = \operatorname{argmin}_a \sum_{k=1}^n (y_k - a)^2$$

令

$$\frac{\partial L}{\partial a} = - \sum_{k=1}^n 2(y_k - a) = 0$$

解得

$$a = \frac{1}{n} \sum_{k=1}^n y_k = \bar{y}$$

与 Q1 中所得总体均值极大似然估计的结果相同，均为样本均值。

计算最小二乘解的代码：

```
stu_a = df2["STUBEHA"].mean()
print(f"STUBEHA 常数估计 a 的最小二乘解：a = {stu_a:.4f}")
```

结果：

```
STUBEHA 常数估计 a 的最小二乘解：a = 0.0411
```

任务5：特征 STUBEHA, TEACHBEHA 的总体均值差异检验

基于 T4 的假设，现需对特征 STUBEHA, TEACHBEHA 的总体均值差异进行检验。请阅读本文档的内容，并导入 `scipy` 库，完成以下任务：

Q1. 简述本情景下应使用成组检验还是成对检验，并写出单侧检验原假设。

应使用成对检验，因为 STUBEHA 表示学生妨碍学习的行为，TEACHBEHA 表示妨碍学习的行为，二者一一对应且具有一定相关性，而成组检验往往用于检验不成对的独立样本。

若欲检验问题为“STUBEHA 的总体均值明显小于 TEACHBEHA 的总体均值”，按成对检验方法，构造样本 $Z_i = X_{\text{STUBEHA},i} - X_{\text{TEACHBEHA},i}$ ，则可以取原假设为：

$$H_0 : \mu_Z = \mu_1 - \mu_2 \geq 0$$

对立假设为：

$$H_1 : \mu_Z = \mu_1 - \mu_2 < 0$$

Q2. 使用 scipy.stats 中的相关方法，执行相应的假设检验。

scipy.stats 中提供了函数 ttest_rel 进行成对t检验，返回t统计量的值与双侧检验p值。由于本题中应采取单侧检验（极端值方向为负），故单侧检验p值需要进行计算。

代码：

```
from scipy.stats import ttest_rel

tvalue, pvalue = ttest_rel(df2["STUBEHA"], df2["TEACHBEHA"])

if tvalue >= 0:
    # 为拒绝原假设(t >= 0)，单侧检验p值应取t值左侧部分概率
    onese_pvalue = 1 - pvalue/2
else:
    onese_pvalue = pvalue/2

print(f"t值为: {tvalue}")
print(f"双侧检验p值为: {pvalue}")
print(f"单侧检验p值为: {onese_pvalue}")
```

结果：

```
t值为: -9.420646242610308
双侧检验p值为: 4.936494108774419e-21
单侧检验p值为: 2.4682470543872093e-21
```

由于单侧检验p值小于0.05，故在显著性水平 $\alpha = 0.05$ 下，有把握拒绝原假设，即认为STUBEHA的总体均值明显小于 TEACHBEHA 的总体均值。

Q3. 基于Q2所得结果，请仔细斟酌并叙述你所得到的结论。

在本问题的成对t检验中，t值为

$$t = \frac{\bar{d} - \mu_0}{s_d / \sqrt{n}}$$

其中 $\bar{d}$ 为每对 STUBEHA 与 TEACHBEHA 样本的差 d 的均值， s_d 为 d 的标准差， μ_0 为零假设中的平均值之差（本问题中 $\mu_0 = 0$ ）。在零假设成立的条件下， t 符合自由度为 $n - 1$ 的t分布， n 为样本数。

p值的定义为“零假设成立的条件下，样本的t统计量取当前t值及更极端值”的概率，“极端值”是利于对立假设的。p值越小，越有把握拒绝原假设，进而肯定对立假设。在本问题中，单侧检验p值为

$$p_{\text{oneside}} = P(T < t | H_0), T \sim t_{n-1}$$

计算得到 $p_{oneside} = 2.4682470543872093 \times 10^{-21}$

这个p值小于0.05，故在显著性水平 $\alpha = 0.05$ 下，有足够的把握拒绝零假设。即可以认为 STUBEHA 的总体均值明显小于 TEACHBEHA 的总体均值。

Q4. 上述结论隐含了犯哪一类错误的可能？相应犯错概率是多少？

第一类错误：在原假设成立的情况下拒绝了原假设（统计量落在拒绝域内）。

第二类错误：在对立假设成立的情况下接受了原假设（统计量不落在拒绝域内）。

由于结论拒绝了原假设，所以只会犯第一类错误。

在显著性水平 $\alpha = 0.05$ 下，上述结论犯第一类错误的概率为：

$$P(\text{第一类错误}) = P(T < t_{\alpha} | H_0) = \alpha = 0.05$$

实验结论

本实验首先进行了基本的数据集读取、缺失值和冗余列等预处理、探索性统计分析等操作，并基于其结果进行了简单的数据可视化分析（散点图、饼图、相关系数矩阵热力图等）。最后，对 STUBEHA、TEACHBEHA 两个特征进行了特征分布校验、参数估计与假设检验。