

蛋白质折叠的路径规划

时分	101	PB23151799
郑天祺	99	PB23151815
王瑞子	89	PB22151746

2025 年 5 月 30 日

摘要

针对蛋白质折叠的路径规划问题，我们完成了以下建模任务：1. 建立蛋白质分子空间结构模型。2. 建立蛋白质分子构象能量模型。3. 获取蛋白质的能量最低构象（自然构象）。4. 规划蛋白质分子从展开构象到能量最低构象的折叠路径。

针对任务一，我们创建了蛋白质的格点 HP 模型和非格点粗粒化模型，格点 HP 模型能大致反应蛋白质分子的折叠状态，粗粒化模型能较好的保留蛋白质主链的螺旋和折叠状态。

针对任务二，我们构建了格点 HP 模型的疏水势能模型和粗粒化模型的相互作用势能模型。均能较好地反应初始构象和最终构象的能量差异以及折叠过程的显著能量下降。

针对任务三，我们采用了基于格点 HP 模型的模拟退火算法以及基于 AlphaFold 的蛋白质构象预测。前者可以大致找到全局的能量最低构象，且同时能够实现以能量为导向预测折叠路径；后者则能够通过深度学习较准确地预测给定序列的能量最低构象。

针对任务四，我们采用了基于非格点粗粒化模型的 RRT* 算法，采用基于 AlphaFold 的蛋白质构象预测为最低能量构象，基于势能下降原则，在蛋白质构象高维空间内进行路径搜索。该算法能够有效规划出蛋白质的折叠路径。同时，我们创新性地引入了终点导向机制，加速了算法搜索。

我们利用上述模型分别对真实蛋白质和随机序列进行了实验，并调整参数，对结果进行展示和对比分析。最后，我们提出了一些实验中待解决的问题，并给出了可能的解决方案。

一、前言

蛋白质折叠是生物物理学和计算生物学中的核心问题之一，其本质是研究蛋白质从一维氨基酸序列自发形成特定三维结构的过程。这一过程的路径规划不仅对理解蛋白质的功能与动力学至关重要，也为药物设计、疾病机制研究等提供了理论基础。然而，蛋白质折叠路径的高维性和复杂性使得其数学建模极具挑战性。

为高效探索蛋白质的构象空间并预测其折叠路径，本研究采用两种互补的建模方法：基于格点模型的退火算法和基于非格点粗粒化模型的 RRT* 算法。

格点 HP 模型与退火算法：HP 模型将氨基酸简化为疏水（H）和亲水（P）两类，并在离散格点上模拟折叠过程，显著降低了计算复杂度。结合模拟退火算法，通过温度参数控制能量优化过程，能够有效避免局部极小值，逐步逼近蛋白质的全局最优构象。但该模型的缺点是仅考虑疏水相互作用且格点模型生成的蛋白质结构过于粗糙。

非格点粗粒化模型与 RRT* 算法：为更贴近真实蛋白质的连续构象空间，我们引入粗粒化模型，并采用 RRT* 这一基于采样的路径规划算法。粗粒化模型通过将蛋白质主链抽象为三维空间球棍模型，在显著减少计算复杂度的同时极大程度保留了蛋白质的螺旋结构和折叠结构。RRT* 通过增量式构建随机树，在保证渐近最优性的同时，高效搜索从展开态到天然态的折叠路径。

通过对比两种模型的路径规划结果，本研究旨在揭示离散与连续表示下蛋白质折叠动力学的共性与差异，同时为多尺度建模提供方法论支持。最终，这一工作可为蛋白质设计、折叠等研究提供更高效的算法框架和理论工具。

二、相关工作

蛋白质折叠是分子生物学领域的核心问题之一，这一过程对生命活动至关重要。蛋白质折叠问题不仅包括预测最终的天然构象（蛋白质结构预测），更深层次的挑战在于揭示蛋白质从非折叠状态到天然构象的动态转变过程，即折叠路径规划。理解折叠路径对于药物设计、生物工程以及理解蛋白质错误折叠疾病的发生机制具有重要意义。

2.1 基于 HP 模型的蛋白质折叠研究

为了简化蛋白质折叠的复杂性，研究人员提出了多种模型。其中，HP（Hydrophobic-Polar）模型是计算生物学中常用的简化模型，它们在模拟蛋白质折叠行为方面发挥了重要作用。

2.1.1 HP 模型

HP 模型将 20 种天然氨基酸简化为两种类型：疏水（H）和亲水（P）。HP 模型的折叠原则是使更多的疏水残基聚集在一起，形成疏水核心，以达到最低能量状态。许多早期关于蛋白质折叠动力学和构象采样的研究都基于 HP 模型进行，因为它显著降低了计算复杂性，使得探索大规模构象空间成为可能。例如，一些研究利用蒙特卡洛（Monte Carlo）模拟或遗传算法在 HP 模型中寻找最低能量构象，以模拟蛋白质的天然状态^[1]。

2.1.2 模拟退火算法在构象搜索中的应用

在基于 HP 模型和格点模型的蛋白质折叠模拟中，寻找最低能量构象通常是一个 NP 难问题。模拟退火 (Simulated Annealing, SA) 算法作为一种启发式优化算法，被广泛应用于解决这类问题 [2]。模拟退火算法通过模拟物理退火过程，从高温开始，逐渐降低温度，允许系统在早期接受一些较差的解以跳出局部最优，最终收敛到全局最优或接近最优的解。在蛋白质折叠中，模拟退火通过迭代执行构象移动 (如链段翻转、末端摆动等) 和能量计算，逐步探索构象空间，最终收敛到能量最低的天然构象。

2.2 基于 RRT* 算法的蛋白质折叠路径规划

传统蛋白质折叠路径的探索主要依赖于分子动力学模拟。然而分子动力学模拟计算成本高昂，难以有效捕捉蛋白质折叠过程中的稀有事件和构象跳跃。随着运动规划 (Motion Planning) 算法在机器人学领域的成功应用，研究者们开始尝试将其引入到生物分子系统的构象路径规划中，其中 RRT* (Rapidly-exploring Random Tree Star) 算法因其渐近最优性和对高维空间的适应性而备受关注。

基于 RRT* 算法的蛋白质折叠路径规划通常包括：构象能量计算，用于评估新生成构象的优劣和路径成本；节点生成，即在构象空间中随机生成新的过程构象，并将其添加到树中；以及 RRT* 算法核心实现，包括选取最近邻节点、扩展新节点、碰撞检测、以及重新布线以优化路径。

2.3 基于现实蛋白质的折叠路径规划

尽管简化模型如 HP 模型和格点模型有助于理解蛋白质折叠的基本原理，但它们无法完全捕捉现实蛋白质的复杂性和多样性。因此，将折叠路径规划方法应用于现实蛋白质，是该领域研究的重要方向。

分子动力学 (Molecular Dynamics, MD) 模拟是一种强大的计算技术，它通过求解牛顿运动方程来模拟原子在给定力场作用下的运动，从而在原子层面研究蛋白质的动态行为和构象变化 [3]。近年来，人工智能在蛋白质结构预测领域取得了突破性进展，尤其是由 DeepMind 开发的 AlphaFold [4]。AlphaFold 及其后续版本利用深度学习技术，能够从氨基酸序列准确预测蛋白质的三维结构，其预测精度已接近实验方法 [5]。因此，对于无法通过实验获得的蛋白质，或者为了快速生成大量随机序列的天然构象，AlphaFold 等人工智能工具也成为获取蛋白质自然构象的有效手段。

三、问题分析

3.1 整体建模任务分析

针对蛋白质折叠的路径规划分析，我们将任务整体分为四步：1. 对蛋白质分子进行空间结构建模。2. 对蛋白质分子的空间构象进行能量建模。3. 获得蛋白质的能量最低构象 (自然构象)。4. 应用 RRT* 算法对蛋白质从初始展开构象到能量最低构象的路径进行规划。

3.2 蛋白质结构建模问题分析

蛋白质分子构象由氨基酸分子之间的肽键和氨基酸残基之间的多种相互作用形成。考虑到应用全原子模型进行分子动力学模拟需要数千个小时 CPU 时间才能捕捉折叠路径，中等复杂度蛋白质的原子级模拟也需要数天才能完成，为了提升模拟速度，我们分别采用了格点化的 HP 模型和非格点的粗粒化模

型。HP 模型主要考虑了氨基酸基团疏水作用对蛋白质构象形成的影响，可以大致反应蛋白质主链基本构象，且格点模型可以极大缩减算法运行时间；而粗粒化模型虽牺牲了氨基酸原子级的细节精度，但能较好的保留蛋白质主链构象的螺旋结构和折叠结构，同时也能极大缩减算法运行时间。

3.3 蛋白质能量建模问题分析

蛋白质分子的势能构成主要源于氨基酸中的各基团和各原子之间相互作用，但是应用全原子模型进行能量建模，其计算量巨大。

本研究采用粗粒化模型将蛋白质分子抽象为氨基酸主链三维球棍模型，将氨基酸抽象为保留残基相互作用属性的粗粒，将肽键抽象为粗粒之间的连边。因此在仅考虑蛋白质主链折叠路径上的构象能量变化的前提下，蛋白质分子的非键合作用可以用继承氨基酸分子属性的粗粒之间的相互作用近似替代，蛋白质分子的键合作用可以用粗粒模型的连边夹角反应的扭曲程度近似替代，由此可以对粗粒模型的蛋白质能量进行建模。

3.4 RRT* 算法问题分析

RRT* 算法可以应用于多种多维空间路径规划问题，但需要完成如下核心运算和操作的定义：

- **搜索空间**：要求能够将所有目标节点包含在搜索空间内，同时尽量降低空间维数和大小。
- **距离**：要求能够准确地反映目标节点的差异大小，同时满足距离的数学性质，即非负性、自反性和三角不等式。
- **节点扩展和步长**：要求在搜索空间内定义，能够实现向目标方向按步长扩展新节点，同时步长需要能够用距离衡量。
- **碰撞**：要求能够真实反映障碍物位置。

四、建模的假设

单链假设将蛋白质拆分为多个亚基，每个亚基由单氨基酸链折叠形成。

键长假设认为蛋白质的肽键长度稳定，近似不变。

相互作用简化假设认为单个由多个物理实体组成的氨基酸实体可以简化为带有物理属性的粗粒子，蛋白质分子由氨基酸的各基团产生的相互作用在粗粒化主链模型上可以简化为氨基酸粗粒的相互作用。

能量最低化假设认为蛋白质的自然构象（最终构象）的能量是蛋白质所有构象空间中的最低能量值，且自然构象的能量远低于直线展开构象的能量，认为蛋白质的折叠过程中能量应保持整体下降趋势。

能量近似假设蛋白质主链构象的能量由非键合作用和键合作用构成，认为非键合作用产生的能量可以由能量占比最大的电势能、范德华力势能、疏水势能近似替代；认为键合作用产生的能量可以统一成当前构象与最终构象的键角差异的数学表示。

五、符号说明

表 1: 符号说明

符号	说明	单位
p	蛋白质（构象）	/
$\mathbf{S}$	蛋白质氨基酸序列	/
$\mathbf{P}$	蛋白质氨基酸位置矩阵	/或 Å
n	蛋白质主链的氨基酸个数	/
a_i	蛋白质主链的第 i 个氨基酸	/
$\mathbf{p}_i$	第 i 个氨基酸的位置向量	/或 Å
$\mathbf{b}_i$	第 i 个与第 $i+1$ 个氨基酸间的伪键向量	/或 Å

六、数学模型建立

6.1 蛋白质结构建模

6.1.1 格点 HP 模型

格点模型和 HP 模型最早由 Dill 等于 1985 年提出 ([1])。格点模型建立在空间中正交单位长度的网格上，每个氨基酸分子按序列中顺序依次放置到网格交点上，在序列中相邻的氨基酸分子放置在格点中时也必须相邻，即相邻氨基酸分子在格点模型中的距离为 1。网格中的每个交叉点最多只能放置一个氨基酸分子，如果在放置氨基酸分子的过程中出现当前所要放置的氨基酸分子没有位置可以放置了，那就说明该构型是不合理的，需要重新放置。格点模型分为二维格点模型和三维格点模型，分别建立在平面和三维空间中。在二维格点模型中放置氨基酸分子时除了序列前两个氨基酸分子外最多只有三个方向可以选择，而在三维格点模型中最多可以有五个方向可选。本实验选取三维格点模型作为退火算法的蛋白质结构模型。为简单起见，将首个氨基酸定位在 $(0, 0, 0)$ 。

HP 模型简单地将氨基酸分为疏水氨基酸 (H) 和亲水氨基酸 (P) 两类，进而将蛋白质氨基酸链编码为 HP 二值序列。在极性溶剂（水）中，疏水相互作用在蛋白质折叠过程中起主要驱动作用，HP 模型通过 H 氨基酸的相邻情况计算疏水相互作用，结合格点模型，可以对蛋白质的能量状态进行方便快捷的估计，便于进行大规模的计算。

基于格点 HP 模型的长度为 n 的蛋白质可以表示为

$$p : (\mathbf{S}, \mathbf{P})$$

氨基酸序列

$$\mathbf{S} = (a_1, \dots, a_n)$$

其中 $a_1, \dots, a_n \in \{H, P\}$ 。

氨基酸 a_i 的位置向量

$$\mathbf{p}_i = (x_i, y_i, z_i)$$

其中 $x_i, y_i, z_i \in \mathbb{Z}$ ，即坐标取整数值。

蛋白质的位置矩阵

$$\mathbf{P} = \{p_{ij}\}_{n \times 3} = (\mathbf{p}_1^T, \dots, \mathbf{p}_n^T)^T = \begin{bmatrix} x_1 & y_1 & z_1 \\ \vdots & \vdots & \vdots \\ x_n & y_n & z_n \end{bmatrix}$$

由位置矩阵可以看出，结构的总自由度为 $3(n-1)$ ，且取值是离散的，这使得路径搜索的复杂度大大降低了。

格点模型是一种对蛋白质结构的简单抽象，在仅考虑氨基酸的疏水相互作用时可以有效地描述蛋白质的空间构象，具有模型复杂度低、构象数量有限、折叠路径可预测、能量计算简单等优势；但由于自由度不足，无法准确地描述现实蛋白质的空间构象，也不适用于计算范德华力、静电相互作用等作用力。为解决这一问题，本实验中进一步引入了非格点的粗粒化模型。

6.1.2 非格点粗粒化模型

粗粒化 (Coarse Grained, CG) 模型是一种蛋白质结构的简化模型，通过忽略掉原子细节将单个原子和伪原子或仅仅伪原子来表示分子，降低蛋白质结构的自由度，实现长时间的分子模拟。本实验中使用的粗粒化模型是非格点的单点模型，即将每个氨基酸简化为单个原子（即 $C\alpha$ 原子），氨基酸之间由伪键连接。在此模型中，为了更精细地计算疏水相互作用、范德华力、静电相互作用等作用力，可以引入组成蛋白质的 20 种氨基酸作为氨基酸序列。为简单起见，可以将长度为 n 的蛋白质氨基酸链的首个氨基酸定位在 $(0, 0, 0)$ ，其余氨基酸由三维坐标 (x, y, z) 表示，结构的总自由度为 $3(n-1)$ 。相邻氨基酸间由伪键连接，每个伪键由极坐标 (l, ϕ, δ) 表示，结构的总自由度也为 $3(n-1)$ 。伪键的极坐标表示和氨基酸的三维坐标表示可以相互转化。

基于非格点粗粒化模型的长度为 n 的蛋白质可以表示为

$$p : (\mathbf{S}, \mathbf{P})$$

氨基酸序列

$$\mathbf{S} = (a_1, \dots, a_n)$$

其中 $a_1, \dots, a_n \in AA$ 。AA 表示 20 种组成蛋白质的氨基酸，用氨基酸的三字母缩写表示为

$$AA = \{\text{Ala, Arg, Asn, Asp, Cys, Gln, Glu, Gly, His, Ile, Leu, Lys, Met, Phe, Pro, Ser, Thr, Trp, Tyr, Val}\}$$

氨基酸 a_i 的位置向量

$$\mathbf{p}_i = (x_i, y_i, z_i)$$

其中 $x_i, y_i, z_i \in \mathbb{R}$ ，即坐标定义在实数域上。

蛋白质的位置矩阵

$$\mathbf{P} = [p_{ij}]_{n \times 3} = (\mathbf{p}_1^T, \dots, \mathbf{p}_n^T)^T = \begin{bmatrix} 0 & 0 & 0 \\ x_2 & y_2 & z_2 \\ \vdots & \vdots & \vdots \\ x_n & y_n & z_n \end{bmatrix}$$

氨基酸 a_i, a_{i+1} 间的伪键 $\mathbf{b}_i$ 的极坐标表示

$$\mathbf{b}_i = (l_i, \phi_i, \theta_i)$$

其中 $l_i \in \mathbb{R}_+$, $\phi_i \in [0, 2\pi)$, $\theta_i \in [0, \pi]$ 。

在一般的单链蛋白质结构中，伪键的长度 l_i 通常在一个固定区间内取值，即

$$l_i \in [l_{mean} - \Delta l, l_{mean} + \Delta l]$$

经大量样本统计，本实验模型取 $l_{mean} = 3.8\text{\AA}$, $\Delta l = 0.4\text{\AA}$ 。通过实验验证，该取值区间能够很好地符合模型实际状态，同时在一定程度上压缩了搜索空间。

蛋白质的伪键极坐标矩阵

$$\mathbf{B} = [b_{ij}]_{n-1 \times 3} = (\mathbf{b}_1^T, \dots, \mathbf{b}_n^T)^T = \begin{bmatrix} l_1 & \phi_1 & \theta_1 \\ \vdots & \vdots & \vdots \\ l_{n-1} & \phi_{n-1} & \theta_{n-1} \end{bmatrix}$$

定义由位置矩阵计算伪键极坐标表示的函数 T ，对蛋白质的位置矩阵 $\mathbf{P}$ ，伪键极坐标矩阵 $\mathbf{B}$ ，有

$$\mathbf{B} = T(\mathbf{P}), \mathbf{P} = T^{-1}(\mathbf{B})$$

T 作用在位置矩阵的每对相邻行向量 $\mathbf{p}_i, \mathbf{p}_{i+1}$ 上，表达式为

$$\mathbf{b}_i = T(\mathbf{p}_i, \mathbf{p}_{i+1}) = (l(\mathbf{p}_i, \mathbf{p}_{i+1}), \phi(\mathbf{p}_i, \mathbf{p}_{i+1}), \theta(\mathbf{p}_i, \mathbf{p}_{i+1})), i = 1, 2, \dots, n-1$$

其中计算键长（即两个位置向量的欧几里得距离）

$$l(\mathbf{p}_i, \mathbf{p}_{i+1}) = \|\mathbf{p}_i - \mathbf{p}_{i+1}\|_2 = \sqrt{(x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2 + (z_{i+1} - z_i)^2}$$

计算在 xOy 平面投影与 x 轴夹角

$$\phi(\mathbf{p}_i, \mathbf{p}_{i+1}) = \begin{cases} \arccos \frac{x_{i+1} - x_i}{((x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2)^{1/2}} & , y_{i+1} - y_i \geq 0 \\ 2\pi - \arccos \frac{x_{i+1} - x_i}{((x_{i+1} - x_i)^2 + (y_{i+1} - y_i)^2)^{1/2}} & , y_{i+1} - y_i < 0 \end{cases}$$

计算与 z 轴夹角

$$\theta(\mathbf{p}_i, \mathbf{p}_{i+1}) = \arccos \frac{z_{i+1} - z_i}{\|\mathbf{p}_i - \mathbf{p}_{i+1}\|_2}$$

T^{-1} 以递推方式作用于 $\mathbf{p}_i$ 和 $\mathbf{b}_i$ 上，即

$$\mathbf{p}_1 = (0, 0, 0)$$

$$\mathbf{p}_i = T^{-1}(\mathbf{b}_i, \mathbf{p}_{i-1}) = (x_{i-1}, y_{i-1}, z_{i-1}) + (l_i \cos \phi_i \sin \theta_i, l_i \sin \phi_i \sin \theta_i, l_i \cos \theta_i), i = 2, \dots, n$$

由 T 和 T^{-1} 可以建立氨基酸位置矩阵和伪键极坐标矩阵间的相互转化，这在后续 RRT* 算法的距离和取样算法中具有重要意义。

基于如上的粗粒化模型，蛋白质的结构可视化如图1,2所示，不同颜色的点代表不同种类的氨基酸伪原子，黑色线段表示伪键。

粗粒化模型在简化蛋白质结构自由度的同时，实现了对现实蛋白质空间构象的较准确模拟，在该模型下可以计算疏水相互作用、范德华力、静电相互作用、肽键扭转力等相互作用，使得能量的建模更精细、更贴合实际；但模型的高复杂度为结构建模的数值估计带来了挑战，在给定伪键的变化量时难以计算三维坐标的变化，这使得后续 RRT* 算法中的步长难以准确估计，需要引入后验的自适应计算来解决这一问题。




图 1: 线粒体核糖体蛋白 S34 的粗粒化模型




图 2: Kunitz 型牛胰蛋白酶抑制剂结构域蛋白的粗粒化模型

6.2 蛋白质能量建模

6.2.1 基于格点 HP 模型的能量建模

HP 模型中，氨基酸被分为疏水 (H) 和亲水 (P) 两类。在极性溶剂中，疏水相互作用表现为疏水氨基酸之间的引力，疏水氨基酸距离越近，蛋白质的疏水势能就越小。

基于这一建模，在格点模型中，可以通过遍历每个疏水氨基酸的邻居，统计其中疏水氨基酸的个数来计算蛋白质的疏水势能。整个蛋白质 $p: (\mathbf{S}, \mathbf{P})$ 的疏水势能 E_p 定义为

$$E_p = -\frac{1}{2} \sum_{a \in \mathbf{S}} \sum_{a' \in N_a} \mathbb{I}(a')$$

其中 a 为氨基酸， N_a 表示氨基酸 a 的六方向邻居集合，即

$$N_a = \{a' \mid \|\mathbf{p}_{a'} - \mathbf{p}_a\|_1 = 1\}$$

$\|\cdot\|_1$ 为 1-范数，即向量分量绝对值求和， $\mathbf{p}_{a'}, \mathbf{p}_a$ 是 a', a 的位置向量。 $\mathbb{I}_H(a)$ 是示性函数，即

$$\mathbb{I}_H(a) = \begin{cases} 1 & , a = H \\ 0 & , a = P \end{cases}$$

6.2.2 基于非格点粗粒化模型的能量建模

基于非格点粗粒化模型，蛋白质分子结构被精简为三维空间的球棍模型，仅保留了氨基酸与肽键，考虑到蛋白质分子势能由非键作用和键合作用构成，而非键作用中静电相互作用、范德华力相互作用和疏水相互作用占折叠构象势能构成约 90%，而键作用的总势能可以根据蛋白质当前构象与其最佳构象之间的键角差异进行描述，因此本模型建构蛋白质能量模型主要考虑了以下四种势能：电势能、范德华力势能、疏水势能、键角约束能量。

电势能 蛋白质分子的电势能近似计算公式为：

$$U_e = \sum_{1 \leq i < j \leq n} k \frac{q_i q_j}{r_{ij}}$$

其中, q_i 表示蛋白质主链上第 i 个氨基酸的带电量, r_{ij} 表示第 i 个氨基酸和第 j 个氨基酸的三维空间欧式距离, k 是静电力常量, 取 $k = 8.99 \times 10^9 \text{ N} \cdot \text{m}^2/\text{C}^2$ 。

范德华力势能 蛋白质分子的范德华力势能近似计算公式为:

$$E_{VDW} = \sum_{1 \leq i < j \leq n} \frac{B}{r_{ij}^{12}} - \frac{A}{r_{ij}^6}$$

其中, A 和 B 是经验参数 $A = 5.96 \times 10^{-3} \text{ kJ} \cdot \text{nm}^6/\text{mol}$, $B = 11.5 \times 10^{-6} \text{ kJ} \cdot \text{nm}^{12}/\text{mol}$

疏水势能 蛋白质分子的疏水势能近似计算公式为:

$$E_{\text{hydro}} = \sum_i^n \gamma \cdot H_{\alpha_i} \cdot \rho_i$$

其中 γ 为比例系数 (约 $2.5 \sim 3.0 \text{ kJ} \cdot \text{\AA}^3 \cdot \text{mol}^{-1}$), H_{α_i} 表示主链第 i 个氨基酸的 Eisenberg 疏水标度 [6]。 ρ_i 表示主链第 i 个氨基酸的邻域 β 碳密度, 其近似计算公式为:

$$\rho_i = \frac{n_{\beta,i}}{\frac{4}{3}\pi R^3}$$

其中, $n_{\beta,i}$ 表示氨基酸 a_i 邻域内的 β 碳数量, 可近似为其邻域内氨基酸的数量。本模型取邻域计算半径 $R = 8\text{\AA}$ 。

键角约束能量 蛋白质分子的键角约束能量近似计算公式为:

$$E_{\text{angle}} = \sum_{i=2}^{n-1} k \cdot (\varphi_i - \varphi_i^c)^2$$

其中 k 为比例系数, 本模型取 $k=1$, φ_i 表示蛋白质主链粗粒化模型在第 i 个粗粒的折叠角, φ_i^c 表示第 i 个粗粒的最优折叠角, 即蛋白质最终构象的粗粒化模型在第 i 个粗粒的折叠角。

粗粒化模型的总势能 由于粗粒化模型忽略了氨基酸分子的空间构象, 仅仅在主链模型结构层面考虑其折叠构象势能, 因此根据经验公式计算所得电势能、范德华力势能、疏水势能、二面角约束能量之间存在数量级差异, 这是由于蛋白质分子的势能主要来源于氨基酸残基各原子间的相互作用力。在仅考虑主链构象的情况下, 需要通过加权平均消除能量的数量级差异。

蛋白质分子的总势能可以表示为:

$$E = w_1 \cdot U_e + w_2 \cdot E_{VDW} + w_3 \cdot E_{\text{hydro}} + w_4 \cdot E_{\text{angle}}$$

该势能函数可以作为蛋白质折叠路径合理性的判定依据 (能量降低原则), 权重数组 $[w_1, w_2, w_3, w_4]$ 是可以调整的超参数。

6.3 蛋白质构象预测

6.3.1 模拟退火算法

模拟退火算法 (simulated annealing, SA) 基于蒙特卡洛方法的思想, 是在一个大的构象空间中搜索全局最优解的常用方法。算法首先将体系加热到很高的温度, 保证体系可以在构象空间的很大范围内随机采样, 然后将温度慢慢降低, 在构象空间中搜索体系的最优结构, 体系可以按照 Metropolis 规则以一定的概率从局部极小态跳出, 最终趋于全局最优解。Shakhnovich 等^[7] 利用模拟退火技术, 研究蛋白质的折叠过程, 发现该能量曲面有很多的局部极小, 结果表明, 从随机构象出发进行模拟退火可以较好找到体系能量最优的构象。

本实验中的模拟退火算法基于格点 HP 模型, 算法的基本步骤如下:

1. 随机生成蛋白质的初始构象, 将首个氨基酸固定在 $(0, 0, 0)$ 。将初始温度设定为 T_0 。
2. 在每次循环内进行多轮迭代寻找能量最小的构象。
3. 在每轮循环结束时降温, 并保存构象变化路径和能量变化情况。
4. 温度低于指定值时结束循环。

模拟退火算法的核心参数包括初始温度 T_0 , 最低温度 T_{min} , 降温因子 $\alpha \in (0, 1)$ 和最大迭代次数 M , 其中循环与迭代的具体实现见 Algorithm 1。

Algorithm 1: 基于格点 HP 模型的模拟退火 (SA Based On HP Model)

Input: $\mathbf{S}, \mathbf{P}_0, T_0, \alpha, T_{min}, M$

Output: 位置序列 $(\mathbf{P}_0, \dots, \mathbf{P}_n)$, 能量序列 $(E_0, \dots, E_n)$

$T \leftarrow T_0$

$E_0 \leftarrow \text{Energy}(\mathbf{S}, \mathbf{P}_0)$ // 计算能量

$k \leftarrow 1$

while $T > T_{min}$ **do**

$E_k \leftarrow E_{k-1}$

$\mathbf{P}_k \leftarrow \mathbf{P}_{k-1}$ // 迭代初值设为上一个记录值

for $i = 0$ **to** M **do**

$\mathbf{P}_{new} \leftarrow \text{GetNewPosition}(\mathbf{P}_k)$ // 随机修改一个伪键得到新的位置

$E_{new} \leftarrow \text{Energy}(\mathbf{S}, \mathbf{P}_{new})$

$\Delta E \leftarrow E_{new} - E_k$

$r \leftarrow \text{random}(0, 1)$ // 在 $[0, 1]$ 内取随机数

if $\Delta E < 0$ **or** $r < e^{-\Delta E/T}$ **then**

$\mathbf{P}_k \leftarrow \mathbf{P}_{new}$

$E_k \leftarrow E_{new}$ // 能量降低或满足 Metropolis 条件, 更新位置和能量

$T \leftarrow \alpha T$ // 按指数趋势降温

if $E_k < E_{k-1}$ **then**

$k \leftarrow k + 1$ // 能量降低时记录位置和能量

对于有较长序列的蛋白质，模拟退火算法的初始温度、最大迭代次数参数需要相应增加，确保迭代次数足够、降温速度较慢，以找到局部最优构象。每次随机生成初始构象，重复运行模拟退火算法，可以较好地找到全局的能量最低构象。

6.3.2 基于 AlphaFold 的蛋白质构象预测

AlphaFold 是一个用于预测蛋白质三维形状的系统，它基于深度学习技术，能够从蛋白质的氨基酸序列推断其结构。蛋白质的结构在很大程度上决定了蛋白质的功能，然而通过实验确定蛋白质结构通常既困难又耗时。

原理简述 AlphaFold [4] 的核心是一个深度卷积神经网络，该网络经过蛋白质数据库 (PDB) 中蛋白质结构的训练，以预测蛋白质中残基对之间距离的离散概率分布 ($P(d_{ij}|S, \text{MSA}(S))$)。这种距离预测比传统的接触预测提供了更丰富的结构信息和训练信号。网络通过联合预测多个距离，能够传播尊重协变、局部结构和邻近残基身份的距离信息。

基于这些预测的距离分布，AlphaFold 构建了一个平滑的蛋白质特异性势能 (V_{distance})，该势能通过对负对数概率进行样条拟合并对所有残基对进行求和得到。此外，网络还会预测骨架扭转角 (φ, ψ) 的离散概率分布 ($P(\varphi_i, \psi_i|S, \text{MSA}(S))$)，这被用于构建扭转角势能 (V_{torsion})。为了防止空间位阻，还引入了 Rosetta 的 $V_{\text{score2_smooth}}$ 项。这些势能项都被设计为可微函数，使得总势能 ($V_{\text{total}}(\varphi, \psi)$) 可以通过梯度下降算法进行优化，从而生成蛋白质结构。结构初始化是通过从预测的扭转值中采样得到，并通过“噪声重启”策略进行多次优化，以收敛到最低势能结构。

使用方法概括 AlphaFold 的使用流程主要包括以下几个阶段：

1. **序列和 MSA 特征提取**: 首先，给定一个蛋白质的氨基酸序列，利用工具（如 HHblits 和 PSI-BLAST）在大型蛋白质序列数据库中搜索相似序列，生成多序列比对 (MSA)。从 MSA 中提取一维序列特征和二维协变特征，作为深度神经网络的输入。
2. **深度神经网络预测**: 这些特征被输入到一个深度残差卷积网络中，该网络预测残基对之间的距离分布（即 distogram）和骨架扭转角分布。
3. **构建蛋白质特异性势能**: 基于预测的距离和扭转角分布，结合防止空间冲突的势能项（如 Rosetta 的 $V_{\text{score2_smooth}}$ ），构建一个平滑的、可微的蛋白质特异性总势能。
4. **梯度下降优化**: 使用梯度下降算法（如 L-BFGS）对构建的总势能进行最小化，通过优化骨架扭转角来生成符合势能的蛋白质三维结构。优化过程通常会进行多次迭代，并采用“噪声重启”等策略来探索不同的构象空间，最终选择最低势能的结构作为最佳候选。

值得注意的是，AlphaFold 在预测时可以处理完整的蛋白质链，避免了传统上对长蛋白质进行结构域分割的需要，尽管 MSA 的计算仍可能使用滑动窗口方法对子序列进行处理。

预测结果展示 使用 AlphaFold 进行蛋白质结构预测展示如下

1. **丝氨酸蛋白酶抑制剂 Kazal 型 1**: <https://alphafold.ebi.ac.uk/entry/P09036>，如图3,4。
2. **核苷二磷酸激酶 3**: <https://alphafold.ebi.ac.uk/entry/Q13232>，如图5,6,7。
3. **用 AlphaFold 预测随机序列**: 如图8,9。




图 3: 丝氨酸蛋白酶抑制剂 Kazal 型 1 图
a




图 4: 丝氨酸蛋白酶抑制剂 Kazal 型 1 图
b



图 5: 核苷二磷酸激酶 3 图
a




图 6: 核苷二磷酸激酶 3 图
b




图 7: 核苷二磷酸激酶 3 图
c




图 8: 随机序列预测图 a




图 9: 随机序列预测图 b

:

6.4 RRT* 算法

6.4.1 RRT* 算法原理

RRT* (Rapidly-Exploring Random Tree Star) 算法是一种基于采样的、可以处理带有非完整约束的多维空间路径规划问题的算法。相较于 RRT (Rapidly-Exploring Random Tree, 快速搜寻随机树) 算法, RRT* 算法通过引入修改父节点和重布线的操作, 能够快速的找出初始路径, 并随着采样点的增加, 不断地对路径进行优化更新, 直到找到目标点或者达到设定的最大循环次数, 即具有渐进优化的特点。

RRT* 算法的核心步骤如下:

1. 初始化树, 将起点设置为根节点, 随后开始循环;
2. 随机在空间中采样;
3. 在已有树中找到离采样点最近的节点;
4. 以该点为起点, 向采样点扩展单位步长, 得到新节点; 若与采样点距离小于单位步长, 则直接取采样点作为新节点;
5. 判断最近节点和新节点间的连线是否与障碍物发生碰撞, 如果发生碰撞则重新取样;
6. 在新节点以固定半径搜索邻近点集, 选择使得新节点代价最小的节点作为父节点, 将新节点加入树中;
7. 对树进行重布线, 以最小化代价为标准对邻近点集的节点重新选择父节点;
8. 判断是否到达目标区域或到达最大迭代次数, 如果是则结束循环。

RRT* 算法的核心参数包括步长 $step$ 、邻域搜索半径 R 和最大迭代次数 M , 其具体实现见 Algorithm 2。

在迭代次数足够的情况下, RRT* 算法能够搜索整个多维空间, 处理非完整约束 (障碍物), 同时渐进地优化路径, 相较于其他基于采样和蒙特卡洛方法的路径搜索算法具有一定的优势; 但在搜索空间维数较高、范围较大时, 基于随机采样的 RRT* 算法需要大量的时间和算力在全空间搜索, 难以找到终点。一个可以有效解决本问题的方法是对取样进行“导航”, 即通过一些机制将取样向终点引导。基于此思想, 本实验引入如下 2 个机制:

- 设定终点取样概率 $p \in [0, 1)$, 在执行取样操作时, 有 p 的概率直接取终点作为样本。
- 设定终点平均权重 $w \in [0, 1)$, 在取随机样本时, 将随机样本坐标 $\mathbf{p}_{rand}$ 与终点坐标 $\mathbf{p}_{goal}$ 加权平均

$$\mathbf{p}_{avg} = (1 - w)\mathbf{p}_{rand} + w\mathbf{p}_{goal}$$

作为最终样本。

经实验验证, 在 p 在 $[0.05, 0.1]$, w 在 $[0.01, 0.05]$ 范围内取值时, 在高维空间内 (即较长链蛋白质的构象空间内), 这两种机制可以有效地降低迭代次数, 加快算法搜索到终点区域的速度, 同时也允许算法绕开障碍, 选择有效路径。

Algorithm 2: RRT* (Rapidly-Exploring Random Tree Star)

Input: $x_{start}, x_{goal}, step, R, M$
Output: 路径 $P = (x_{start}, \dots, x_{goal})$
 $T \leftarrow \{x_{start}\}$ // 初始化树
for $i = 1$ **to** M **do**
 $x_{rand} \leftarrow Sample()$ // 随机在空间中采样
 $x_{near} \leftarrow \operatorname{argmin}_{x \in T} Distance(x_{rand}, x)$ // 寻找最近节点
 $x_{new} \leftarrow Steer(x_{near}, x_{rand}, step)$ // 向采样点方向扩展新节点
 if $CollisionFree(x_{near}, x_{new})$ **then**
 // 判断是否碰撞
 $X_{neighbor} \leftarrow \{x \mid x \in T, Distance(x, x_{new}) < R\}$ // 寻找邻近点集
 $x_{parent} \leftarrow ChooseParent(x_{new}, X_{neighbor})$ // 选择最优父节点
 $T \leftarrow T \cup x_{new}$ // 将新节点加入树中
 $T \leftarrow Rewire(T, X_{neighbor})$ // 重新布线
 if $Distance(x_{new}, x_{goal}) < step$ **then**
 // 判断是否到达终点区域
 $P \leftarrow (x_{goal}, x_{new})$
 while $Parent(x)$ **do**
 $P \leftarrow P \cup x$
 $x \leftarrow Parent(x)$ // 获取路径
 return $Reverse(P)$
return $None$ // 迭代结束, 未到达终点区域

6.4.2 RRT* 算法在蛋白质折叠路径规划中的应用

回顾问题分析中的内容, 将 RRT* 算法应用于蛋白质折叠路径规划问题, 需要完成如下概念的定义:

- **搜索空间:** 要求能够将所有蛋白质构象包含在搜索空间内, 同时尽量降低空间的维数和大小以降低搜索算法的复杂度。采样范围大小也由搜索空间决定。
- **距离:** 要求能够准确地反映蛋白质构象之间的差异大小, 同时满足距离的数学性质, 即非负性、自反性和三角不等式。
- **节点扩展和步长:** 要求在搜索空间内定义, 能够实现向目标方向按步长扩展新节点, 同时步长需要能够用距离衡量。
- **碰撞:** 要求碰撞能够引导蛋白质向正确方向折叠, 障碍物不能覆盖终点区域, 同时符合现实情境。

现实中蛋白质折叠的主要驱动力是体系能量的降低, 在 RRT* 算法中也应当体现能量对折叠的引导作用, 同时需要考虑到算法中能量建模的近似性, 给予一定的松弛区间。

基于如上要求, 本实验中上述 RRT* 算法核心内容定义如下:

搜索空间 将长度为 n 的蛋白质氨基酸链首个氨基酸固定在 $0, 0, 0$, 此时蛋白质的自由度为 $3(n-1)$ 。若以每个氨基酸 (除首个) 的三维坐标作为变量, 则搜索空间的维度为 $3(n-1)$, 且每个变量的取值均为实

数集，对于长链蛋白质而言，这个搜索空间相当大，对算法的复杂度降低问题带来了很大的挑战。此外，这种建模不符合实际蛋白质的特征，即相邻氨基酸的 $C\alpha$ 原子之间的距离位于一个范围较小的固定区间之内。

为了兼顾相邻氨基酸距离约束条件和降低算法复杂度的要求，本实验将搜索空间设定在伪键上，同时将伪键用极坐标表示以直观地展示伪键长度区间。基于广泛的样本统计和建模计算，本实验中伪键键长范围设置在 $[3.4, 4.2]$ （单位：Å）内。将伪键极坐标用上文中矩阵 $\mathbf{B}$ 表示，则搜索空间可以表示为

$$\{\mathbf{B} \mid l_i \in [3.4, 4.2], \phi_i \in [0, 2\pi), \theta_i \in [0, \pi]\}$$

此时搜索空间的维度虽然仍是 $3(n-1)$ ，但由于限制了键长的取值，搜索空间的范围大大减小，同时也能够更有效地描述蛋白质的现实构象，避免折叠路径上出现不符合实际的构象节点。基于搜索空间的定义，算法的起点设置为

$$\mathbf{b}_i = (3.8, 0, 0), i = 1, \dots, n-1$$

即起点的构象是展开的，氨基酸在 z 轴上按直线均匀排列。

距离 为了描述蛋白质构象之间的差异大小，同时满足距离的性质，本实验中构象间的距离定义为两种构象每对对应氨基酸间欧氏距离的平方和，即对蛋白质构象 $p_1 : (\mathbf{S}_1, \mathbf{P}_1)$, $p_2 : (\mathbf{S}_2, \mathbf{P}_2)$ ，构象间的距离

$$Distance(p_1, p_2) = \sum_{i=2}^n \|\mathbf{p}_{1,i} - \mathbf{p}_{2,i}\|_2^2 = \sum_{i=2}^n [(x_{1,i} - x_{2,i})^2 + (y_{1,i} - y_{2,i})^2 + (z_{1,i} - z_{2,i})^2]$$

这一距离定义能够体现蛋白质构象间每对氨基酸的距离关系，进而描述整体的差异大小；同时，根据向量 2-范数的性质，容易证明这一定义满足距离的非负性、自反性和三角不等式。在实验中，该定义表现出良好的效果。

节点扩展和步长 本实验算法的搜索空间定义在伪键的极坐标上，则节点也需要在伪键极坐标上扩展得到。考虑到极坐标三个分量取值范围不同，为同时满足调节步长的需求，本实验中采用比例 $\alpha \in [0, \infty)$ 定义步长，即伪键 $\mathbf{b}_i = (l_i, \phi_i, \theta_i)$ 的变化量为

$$\Delta \mathbf{b}_i = \alpha(s_{l_i} \Delta l, s_{\phi_i} \cdot 2\pi, s_{\theta_i} \pi) = \alpha(s_{l_i} \cdot 0.4, s_{\phi_i} \cdot 2\pi, s_{\theta_i} \pi)$$

其中 $s_{l_i}, s_{\phi_i}, s_{\theta_i}$ 表示取值的符号，由起点和采样点的分量大小关系决定，使扩展方向指向采样点方向。若本次节点扩展操作中该伪键对应的起点伪键为 $\mathbf{b}_i^0$ ，终点伪键为 $\mathbf{b}_i'$ ，则

$$(s_{l_i}, s_{\phi_i}, s_{\theta_i}) = \text{Signal}(\mathbf{b}_i' - \mathbf{b}_i^0)$$

Signal 为符号函数，即

$$\text{Signal}(x) = \begin{cases} 1 & , x \geq 0 \\ -1 & , x < 0 \end{cases}$$

这样定义步长可以实现在伪键极坐标搜索空间内移动指定距离，满足节点扩展算法的需求，但同时也为步长的距离表示带来了挑战：在设置相同步长时，两个构象之间的距离变化范围很大，无法划定确定的上下限。为了解决这一问题，本实验中的 RRT* 算法引入了每步距离的后验最大似然估计，将每步的距离定义为执行该步前算法每步移动距离的平均值。这一估计方法的合理性包括：

- 每步的移动距离可以视为一个随机变量，其均值是确定的；当样本点足够多时，根据大数定律，样本的均值将收敛于随机变量的均值，使得这一估计具有稳定性；

- 算法中仅有判断终点区域时需要应用步长的距离表示，对表示的准确度要求不高；
- 对于自然构象的蛋白质，从直线构象出发到自然构象附近往往需要相当多的迭代步数，这使得样本点的数量得到了保证；
- 相较于计算准确的移动距离区间，这一估计具有范围较小、时间复杂度低等优势。

将该估计方法应用于实验中，在众多样本上均表现良好，进一步证明了这一估计方法的合理性。

在节点扩展完毕后，比较树中节点和扩展后的节点、随机采样节点间的距离，选择距离较短的节点作为树的新节点。

碰撞 蛋白质折叠的驱动力在于体系能量的降低，在设计蛋白质的折叠路径规划算法时，应当将能量纳入考虑，并让其在算法搜索的过程中起到引导作用。一种直接的思路是在构象空间中建立能量的梯度场，但对于较长链的蛋白质而言，构象空间维度太高、范围太大，建立梯度场需要极大量的采样和能量计算，复杂度甚至远高于搜索算法本身；同时，由于粗粒化能量建模的近似性，这一梯度场往往不够准确，无法将终点安排在梯度场的局部极小值点。这些负面因素使得建立梯度场的想法很难付诸实践，且对折叠路径规划没有起到良好的引导效果。这一思路的不可行性给了我们一个提示：能量应该作为一种后验的验证指标，即应当先在构象空间中取样，后计算能量来验证取样的有效性。

在 RRT* 算法中，一些合理的障碍物编排可以阻止算法向非终点区域方向寻找，起到压缩搜索空间，引导算法更快到达终点区域的作用。例如在二维寻路的 RRT* 算法中，如果在起点到终点的较短路径两侧设置“围墙”，就能让算法沿着“围墙”里的路径快速到达终点区域。障碍物碰撞的判断在 RRT* 算法中是后验的，位于取样与节点扩展之后。结合上面关于能量的论述，我们想到：可以将能量是否下降作为算法中与“障碍物”碰撞的判断标准，进而引导算法沿着能量下降的方向更快地到达目标区域。

本实验中 RRT* 算法的碰撞判断基于能量变化定义，即对起点构象 $p_1 : (\mathbf{S}_1, \mathbf{P}_1)$ ，终点构象 $p_2 : (\mathbf{S}_2, \mathbf{P}_2)$ ，碰撞判断

$$CollisionFree(p_1, p_2) = (Energy(p_1) - Energy(p_2) \geq -loose)$$

理论上，起点构象能量与终点构象能量的差值应当大于 0，即在折叠过程中能量展现出单调下降的趋势。但实际上只需要该差值大于一个给定的下界，理由包括：

- 现实中的蛋白质由能量降低方向引导折叠，但过程中能量不是单调递减的。在溶剂的 pH、环境温度、分子伴侣、细胞器结构和热休克蛋白的辅助等因素影响下，蛋白质在折叠过程中会允许小范围的能量上升，即越过“能垒”，只在整体上呈现能量下降的趋势。
- 算法上，在粗粒化的蛋白质能量建模中无法考虑到复杂的原子间相互作用，计算出的能量值是对真实能量的近似，需要一定的缓冲区间。

实验中将这个给定下界设为 $-loose$ 。根据蛋白质氨基酸链长度的不同，允许的松弛值 $loose$ 也有差异，越长的蛋白质往往需要更大的松弛值。本实验中采用起点和终点的能量差值来计算松弛值，即

$$loose = \beta(Energy(p_{start}) - Energy(p_{goal}))$$

实验中， β 可以在 $[0, 0.1]$ 范围内取值，在兼顾模型符合实际性的同时有效地加快了算法搜索的进度，基于能量的碰撞定义对蛋白质折叠表现出良好的引导效果。

实验编号	序列长度	初始温度	终止温度	降温因子	最大迭代次数	最终构象能量
1	20	30.0	1E-3	0.95	1000	-11
2	30	50.0	1E-3	0.95	1500	-15
3	40	100.0	1E-3	0.95	2000	-11
4	40	100.0	1E-3	0.95	2000	-13
5	40	100.0	1E-3	0.95	2000	-20

表 2: 基于格点 HP 模型的模拟退火算法运行参数与结果

七、结果与对比

7.1 基于格点 HP 模型的模拟退火算法

基于格点 HP 模型的模拟退火算法的实现见附件文件 `code/HPSA.py`。

实验中的氨基酸序列在指定序列长度后由程序随机生成得到。共进行 5 次实验，每次实验执行 10 轮模拟退火算法。对于序列较长的蛋白质，设置较高的初始温度和较大的迭代次数，序列长度、初始温度、终止温度、降温因子、最大迭代次数、最终构象能量见表 2。

随机生成的序列为：

1. P H P P H P H P P H P P H P H P H P
2. H H H H H P H H H P H H H P H H H P P P P H P P P P
3. P P P P P H H H P P P H H P P P H P P P P H P H H H P H H H P H H H P
4. H H P H H P P P P H P H H P P P P P H H H P P P P P H H H P P P H P P P
5. H P H H H H P H P P H P P H H H H P H P H P P H P H H P P P H H P H P H P H

最终构象如图 10 至 14 所示，图中橙色点表示 H 氨基酸，蓝色点表示 P 氨基酸，黑色线段表示肽键。




图 10: 最终构象 1




图 11: 最终构象 2




图 12: 最终构象 3

折叠过程构象见附件视频 `/result/HPSA/HP1.mp4` 至 `HP5.mp4`。




图 13: 最终构象 4




图 14: 最终构象 5

运行时命令行输出见附件文本 /result/HPSA/output.txt。

观察折叠过程和结果，发现：

- 折叠结果表现出 H 氨基酸聚簇的特征，满足疏水相互作用能量降低的趋势；
- 折叠过程中表现出先展开再重新聚合的特征，这表明在高温时结构会先迭代至展开构象，降温时再重新聚合到低能量状态，与现实中的蛋白质加热后降温聚合表现出一致性；
- 折叠过程中能量表现出递减的趋势，H 氨基酸占比越大的蛋白质最终能量往往较低。

基于上述实验结果，可以认为本实验中基于格点 HP 模型的模拟退火算法能够大致找到全局的能量最低构象，且同时能够实现以能量为导向预测折叠路径，对于蛋白质构象的预测能够起到一定的指导作用。

7.2 基于非格点粗粒化模型的 RRT* 算法

7.2.1 真实蛋白质的实验结果

本实验的真实蛋白质构象来源于 AlphaFold 数据库的 pdb 文件，文件中存储了蛋白质天然构象每个原子的中心坐标。基于粗粒化的单原子模型，我们选取每个氨基酸的 $C\alpha$ 原子作为氨基酸的中心。

本实验共选取 8 种真实存在的单链蛋白质构象（见 /data/real 中的 pdb 文件），依次为：

1. 线粒体核糖体蛋白 S34 (28S ribosomal protein S34, mitochondrial)
2. Kunitz 型牛胰蛋白酶抑制剂结构域蛋白 (KunitzBovine pancreatic trypsin inhibitor domain protein)
3. Kunitz 型丝氨酸蛋白酶抑制剂 7 (Kunitz-type serine protease inhibitor 7)
4. 线粒体核糖体小亚基 S34 (Mitochondrial ribosomal protein S34)
5. 核苷二磷酸激酶 (Nucleoside diphosphate kinase)
6. 胰蛋白酶抑制剂 (胰腺型) (Pancreatic trypsin inhibitor)
7. 精液蛋白 24B6 (Seminal fluid protein 24B6)
8. 丝氨酸蛋白酶抑制剂 Kazal 型 1 (Serine protease inhibitor Kazal-type 1)

对如上蛋白质，均以 z 轴上直线展开构象为起点，自然构象为终点运行一次 RRT* 算法寻找折叠路径。实验中算法参数统一设为：

- 伪键键长范围: $[3.4, 4.2]$
- 能量权重数组: $[1, 10, 10000, 1000]$
- 能量松弛系数: $loose = 0.05$
- 终点取样概率: $p = 0.1$
- 终点平均权重: $w = 0.05$
- 步长: $\alpha = 0.02$
- 最大迭代次数: $M = 10000$
- 近邻搜索范围: $R = 10n^2$

算法运行会输出迭代过程中的迭代次数与当前最小距离, 找到路径后会输出路径长度、可视化的折叠动画和能量曲线。算法部分结果如表3所示。每种蛋白质的折叠过程构象见附件文件夹 /result/RRTStar/Real 中的视频, 运行时命令行输出见相同文件夹中的文本。

实验编号	序列长度	初始能量	迭代步数	过程构象数	最终构象能量
1	218	390.7868K	363	121	13.4008K
2	70	117.7144K	259	89	6672.389
3	84	145.9106K	251	77	4269.777
4	215	396.0355K	249	115	12.39365
5	275	501.0812K	325	107	6057.035
6	100	175.1017K	302	94	-405.6538
7	82	150.3687K	670	74	-811.3134
8	79	144.0497K	283	113	-1748.526

表 3: 基于非格点粗粒化模型的 RRT* 算法部分运行结果

根据初步的实验结果, 我们发现如下特征:

- 蛋白质的初始能量 (直线展开态能量) 远高于最终构象能量 (自然态), 且过程中蛋白质构象的能量整体呈现出明显的下降趋势, 即蛋白质可以找到一条能量下降的折叠路径, 这表明我们的能量建模是符合实际的。
- 在不同蛋白质实验中迭代步数均不超过 1000, 算法均能以较快速度收敛。由于 RRT* 算法本身的随机性, 在相同步长设定下, 迭代步数不是固定的, 但总体上序列较长的蛋白质需要更多的迭代步数找到终点。
- 在不同蛋白质实验中, 折叠路径上的构象数大约在 100 个上下。同样由于 RRT* 算法的随机性, 在相同步长设定下, 过程构象数不是固定的, 但总体上序列较长的蛋白质折叠路径上构象数也较多。
- 在折叠过程动画中, 我们发现算法找到的路径整体呈现出先折叠出局部结构 (螺旋、折叠等)、再折叠成整体构象的状态, 这与现实中的蛋白质折叠过程也是一致的。

7.2.2 随机生成氨基酸序列的实验结果

为展示本实验的 RRT* 算法在未知蛋白质折叠路径预测中的作用，本实验随机生成了 3 段不同长度的氨基酸序列，利用 AlphaFold 预测了序列的自然态（见 /data/random 中的 pdb 文件），并在其上进行了实验。算法参数统一设为：

- 伪键键长范围：[3.4, 4.2]
- 能量权重数组：[1, 10, 10000, 1000]
- 能量松弛系数： $loose = 0.05$
- 终点取样概率： $p = 0.1$
- 终点平均权重： $w = 0.05$
- 步长： $\alpha = 0.02$
- 最大迭代次数： $M = 10000$
- 近邻搜索范围： $R = 10n^2$

算法部分结果如表4所示。每种蛋白质的折叠过程构象见附件文件夹 /result/RRTStar/Random 中的视频，运行时命令行输出见相同文件夹中的文本。

实验编号	序列长度	初始能量	迭代步数	过程构象数	最终构象能量
1	103	119.0137K	1300	89	2447.95
2	50	105.8894K	290	100	685.4244
3	151	179.6891K	1000	137	657.4803

表 4: 在随机蛋白质上的 RRT* 算法部分运行结果

根据实验结果，我们发现如下特征：

- 与真实蛋白质类似，蛋白质的初始能量远高于最终构象能量，且过程中蛋白质构象的能量整体呈现出明显的下降趋势，即蛋白质可以找到一条能量下降的折叠路径。
- 在不同蛋白质实验中迭代步数均不超过 1500，算法均能以较快速收敛。
- 在不同蛋白质实验中，折叠路径上的构象数大约在 100 个上下。
- 在折叠过程动画中，与真实蛋白质类似，算法找到的路径整体呈现出先折叠出局部结构（螺旋、折叠等）、再折叠成整体构象的状态，这与现实中的蛋白质折叠过程是一致的。

实验说明，我们设计的 RRT* 算法在处理未知蛋白质的折叠路径规划时也表现出相对良好的性能。

7.2.3 不同步长的对比实验

在初步实验中，步长统一设为 0.02 时，算法在不同长度的蛋白质上均能找到折叠路径。对于序列较长的蛋白质，算法的表现令人满意，但在序列较短的蛋白质上，折叠过程和能量曲线表现出了明显的不平滑性，甚至在能量曲线中出现了相当多的锐角折线，这说明对于较短的蛋白质，算法可能需要选择较短的步长。

为探索较短步长是否更适合短链蛋白质，同时是否会影响算法的迭代次数和搜索效果，本实验在长度为 70 的 Kunitz 型牛胰蛋白酶抑制剂结构域蛋白（初步实验编号 2）上应用不同的步长，其余参数与初步实验保持一致。算法的部分结果如表5所示。

实验编号	步长	迭代步数	过程构象数
1	0.005	1501	365
2	0.01	707	206
3	0.02	259	89
4	0.03	88	68

表 5: 不同步长的 RRT* 算法部分运行结果

折叠过程构象见附件文件夹 /result/RRTStar/Different Stepsize 中的视频，运行时命令行输出见相同文件夹中的文本。

根据实验结果，我们发现：

- 在不同步长设定下，给定足够多的迭代次数，算法依然可以有效地找到终点；
- 对于同一个蛋白质，其它参数相同时，步长越短，算法找到终点所需的迭代步数越多，路径上的构象数也越多。
- 由于过程构象数增加，折叠过程与能量曲线表现出了更高的平滑度，折线锐角明显减少。

实验证明：步长越短，折叠路径上构象越多，折叠过程和能量曲线越平滑，但需要的迭代次数明显增加；步长越长，算法找到终点的速度越快，但折叠过程中可能出现明显的不平滑现象。在实际应用中，需要权衡折叠过程平滑性和算法处理的速度，寻找一个相对平衡的步长。一般而言，对于短链蛋白质应当选择较小的步长，确保折叠过程和能量变化足够稳定；对于长链蛋白质则应当选择较大的步长，避免出现最大迭代次数不足、算法无法找到终点的情况。

7.2.4 不同终点引导的对比实验

对于序列较长的蛋白质，算法的搜索空间较大，效率较低。为了使算法更快地找到终点，本实验引入了“终点引导”机制，即终点取样概率 p 和终点平均权重 w 。具体的机制为：

- 设定终点取样概率 $p \in [0, 1)$ ，在执行取样操作时，有 p 的概率直接取终点作为样本。
- 设定终点平均权重 $w \in [0, 1)$ ，在取随机样本时，将随机样本坐标 $\mathbf{p}_{rand}$ 与终点坐标 $\mathbf{p}_{goal}$ 加权平均

$$\mathbf{p}_{avg} = (1 - w)\mathbf{p}_{rand} + w\mathbf{p}_{goal}$$

作为最终样本。

为了证明该机制在长链蛋白质路径规划中对算法加速的有效性，本实验在长度 275 的核苷二磷酸激酶（初步实验编号 5）上分别测试不同终点取样概率和终点平均权重的效果，对终点取样概率组，终点平均权重统一取 0；对终点平均权重组，终点取样概率统一取 0.1；其余参数和初步实验保持一致（迭代步数上限为 10000），算法的迭代步数如表6、7所示。

实验编号	终点取样概率	迭代步数
1	0	未找到路径
2	0.05	753
3	0.1	292
4	0.2	151
5	0.5	93

表 6: 不同终点取样概率的 RRT* 算法部分运行结果 ($w=0$)

实验编号	终点平均权重	迭代步数
1	0	439
2	0.05	303
3	0.1	692
4	0.2	未找到路径

表 7: 不同终点平均权重的 RRT* 算法部分运行结果 ($p=0.1$)

折叠过程构象见附件文件夹 /result/RRTStar/Different p 和 /result/RRTStar/Different w 中的视频，运行时命令行输出见相同文件夹中的文本。

根据实验结果，我们发现：

- 对于长链蛋白质，在其它参数相同时，引入终点取样概率和终点平均权重均能够有效地加速搜索，使算法更快地找到终点。
- 一定范围内，终点取样概率和终点平均权重越大，算法的搜索速度就越快。
- 相较于终点平均权重，终点取样概率的提升对算法的搜索速度影响更大。
- 在终点平均权重过大时，算法会陷入停滞，迭代次数明显增加，甚至导致路径规划失败。

实验结果证明了一定取值范围内的终点取样概率和终点平均权重对加速算法搜索的有效性。对于终点平均权重过大时算法无法完成寻路的问题，一个可能的解释是：算法的折叠路径由终点引导，而障碍物由能量降低确定；在终点取样概率和终点平均权重过大时，算法倾向于寻找前往终点的“直线”路径，没有考虑到路径上可能存在的高能量构象，持续地“碰壁”，最终导致算法寻路失败。在终点取样概率过大时，也会出现类似的情况。

八、结论

本实验为解决蛋白质自然构象预测和折叠路径规划问题，解决了如下的主要问题：

建立蛋白质分子空间结构模型：我们创建了蛋白质的格点 HP 模型和非格点粗粒化模型，格点 HP 模型能大致反应蛋白质分子的折叠状态，粗粒化模型能较好的保留蛋白质主链的螺旋和折叠状态。

建立蛋白质分子构象能量模型：我们构建了格点 HP 模型的疏水势能模型和粗粒化模型的相互作用势能模型，均能较好地反应初始构象和最终构象的能量差异以及折叠过程的显著能量下降。

获取蛋白质的能量最低构象（自然构象）：我们采用了基于格点 HP 模型的模拟退火算法以及基于 AlphaFold 的蛋白质构象预测。前者可以大致找到全局的能量最低构象，且同时能够实现以能量为导向预测折叠路径；后者对能量最低构象的定位更为准确。

规划蛋白质分子从展开构象到能量最低构象的折叠路径：我们采用了基于非格点粗粒化模型的 RRT* 算法，采用基于 AlphaFold 的蛋白质构象预测为最低能量构象，基于势能下降原则，在蛋白质构象高维空间内进行路径搜索。该算法能够有效规划出蛋白质的折叠路径。同时，为加快搜索速度，算法创新性地引入了终点取样概率和终点平均权重机制，均能有效地加快算法的搜索速度。

九、问题

9.1 蛋白质结构的更精细建模

本实验中采用了两种蛋白质结构建模，即格点模型和粗粒化单原子模型。这两种模型均具有结构简单、结构自由度低的特点，能够支持一定精度的能量近似计算，但要描述现实的蛋白质结构，这两种模型还有不少不足，如无法描述氨基酸残基与主链间的相互作用、无法描述原子间的相互作用（如氢键）等。

为了描述氨基酸残基与蛋白质主链间的相互作用，另一种粗粒化的建模方式为双原子模型，即利用两个伪原子分别表示氨基酸的残基与主链（ C_α 原子）。粗粒化双原子模型能够描述残基与主链间的相互作用，且能将静电相互作用、范德华力、疏水相互作用等作用力区分到残基和主链上；同时，双原子模型内蕴了氨基酸的旋转自由度，能够更准确地描述蛋白质的空间构象。复杂度上，相较于单原子模型，双原子模型多出了一倍的原子，带来了翻倍的复杂度，对算法带来了一定的挑战；同时，双原子模型需要更准确的能量建模，需要对残基和主链分别应用能量分析，这也具有一定的难度。在之后的实验拓展中，我们会考虑引入双原子模型，同时更新能量建模，以更准确地描述蛋白质的空间构象和折叠过程。

尽管双原子模型已经具有相当高的准确性，却仍然无法描述蛋白质的原子间相互作用，如非肽键化学键和氢键等。为了描述如此精细的相互作用，必须引入全原子模型，即将蛋白质的每一个原子均反应在模型之中。这个模型的复杂度极高，对算力和算法均具有很高的要求，很难再采用如 RRT* 算法的路径规划算法（采样空间过大）。为了解决全原子模型下的构象预测和折叠路径规划问题，目前的主流方法是引入强化学习和深度学习算法（如 AlphaFold）。虽然这类算法具有良好的预测效果，但往往难以对结果进行解释和系统分析，我们依然需要继续探索一个具有高可解释性的、具备完善数学背景和建模的全原子模型路径规划算法。

9.2 蛋白质能量的更精细建模

由于结构模型的限制，本实验在格点 HP 模型中仅考虑到疏水相互作用，在粗粒化单原子模型中仅考虑到疏水相互作用、范德华力、静电相互作用和键角约束，且通过引入超参数来平衡作用的数量级。为了描述氢键、原子间相互作用等产生的能量变化，依然需要更精确的能量建模。

除了引入全原子模型，一种可能的氢键能量建模是为残基添加“极性基团数量”属性，根据残基上的极性基团数量预测其形成氢键的概率。但由于氢键具有固定的方向，难以用伪原子定量描述，为了准确地计算氢键能量，全原子模型依然是必要的。

参考文献

- [1] K. A. Dill, “Theory for the folding and stability of globular proteins,” *Biochemistry*, vol. 24, no. 6, pp. 1501–1509, 1985.
- [2] S. Kirkpatrick, C. D. Gelatt, and M. P. Vecchi, “Optimization by simulated annealing,” *Science*, vol. 220, no. 4598, pp. 671–680, 1983.
- [3] M. Karplus and G. A. Petsko, “Molecular dynamics simulation of proteins,” *Nature*, vol. 347, no. 6294, pp. 631–639, 1990.
- [4] A. W. Senior, R. Evans, J. Jumper, J. Kirkpatrick, L. Sifre, T. Green, C. Qin, A. Židek, A. W. R. Nelson, A. Bridgland, H. Penedones, S. Petersen, K. Simonyan, S. Crossan, P. Kohli, D. T. Jones, D. Silver, K. Kavukcuoglu, and D. Hassabis, “Improved protein structure prediction using potentials from deep learning,” *Nature*, vol. 577, no. 7792, pp. 706–710, 2020.
- [5] J. Jumper, R. Evans, A. Pritzel, T. Green, M. Figurnov, O. Ronneberger, K. Tunyasuvunakool, R. Bates, A. Židek, A. Potapenko, *et al.*, “Highly accurate protein structure prediction with alphafold,” *Nature*, vol. 596, no. 7873, pp. 583–589, 2021.
- [6] D. Eisenberg, R. M. Weiss, and T. C. Terwilliger, “The hydrophobic moment detects periodicity in protein hydrophobicity,” *Proceedings of the National Academy of Sciences*, vol. 81, no. 1, pp. 140–144, 1984.
- [7] E. Shakhnovich and A. Gutin, “Formation of unique structure in polypeptide chains: Theoretical investigation with the aid of a replica approach,” *Biophysical Chemistry*, vol. 34, no. 3, pp. 187–199, 1989.